.UBA fiuba
FACULTAD DE INGENIERÍA

Procesamiento de Lenguaje Natural I

Vectorización de texto

Docentes:
MSc. Fernando Silva
MSc. Josselyn Ordoñez

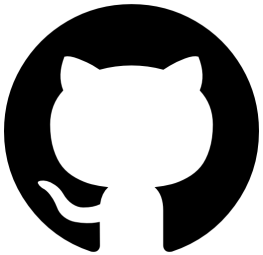
emails: fernandosilva.clases2@gmail.com
josselynsofia@gmail.com

Programa del curso

Clase 1: Introducción a NLP, Vectorización de documentos.
Clase 2: Word embeddings.
Clase 3: Redes recurrentes: Elman, LSTM y GRU.
Clase 4: Modelos de lenguaje y generación de secuencias.
Clase 5: CNNs para PLN.
Clase 6: Modelos Seq2seq.
Clase 7: Mecanismo de atención, Transformers.
Clase 8: Grandes modelos de lenguaje.

*Unidades con desafíos de código a presentar al finalizar el curso.

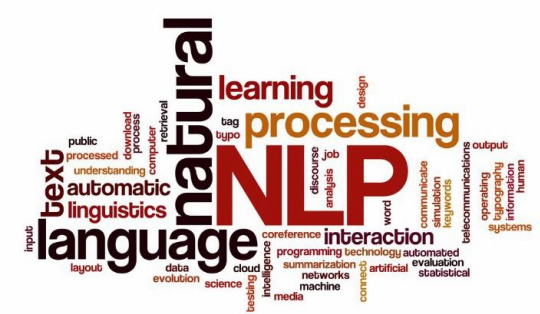
Link Github de la materia



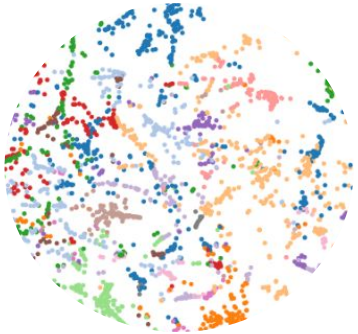


https://github.com/FIUBA-Posgrado-Inteligencia-Artificial/procesamiento_lenguaje_natural

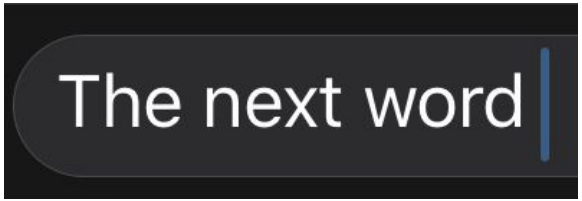
Desafíos propuestos



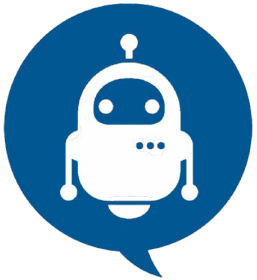
Vectorización de texto



Word embeddings



Generación de secuencias



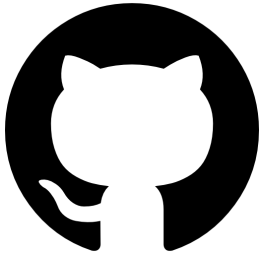
Modelos seq2seq

¿Cómo se entregan las resoluciones?

https://forms.gle/wsWkQJWAFeh6g6qv5

Envían por formulario el link del repositorio, ingresando sus datos.





¿Cómo se evaluarán los desafíos?

Nota máxima si la primera entrega se hace hasta última hora de Argentina del jueves de la clase…

	1	2	3	4	5	6	7	8
Desafío 1	10	10	10	9	9	8	7	6
Desafío 2		10	10	10	9	9	8	7
Desafío 3				10	10	10	9	8
Desafío 4						10	10	10

Los desafíos son individuales o en pareja.

PARA APROBAR EL CURSO TODOS LOS DESAFÍOS DEBEN SER ENTREGADOS Y EVALUADOS SATISFACTORIAMENTE ANTES DE LA FECHA DEL CIERRE DE NOTAS

Agenda



- Introducción al Procesamiento de Lenguaje Natural (NLP)
- Historia del NLP
- Aplicaciones de NLP
- Tareas de NLP
- Preprocesamiento de Texto
- Vectorización de Texto
- Machine Learning para NLP

Introducción al Procesamiento de Lenguaje Natural (NLP)

¿Qué es el lenguaje?
¿Qué se necesita para entenderlo?

¿Qué es el lenguaje?

Desde un punto de vista de la **Lingüística**:

- El Lenguaje es un sistema de símbolos más reglas. Contempla semántica, sintaxis, y es pragmática.

- Chomsky menciona la idea de gramática generativa:
  - Donde tenemos un conjunto de reglas capaces de generar todas las oraciones correctas de un idioma.
  - Con pocas reglas podemos generar infinitas oraciones.
  - **En NLP clásico se intentó modelar lenguaje con reglas tipo Chomsky.**

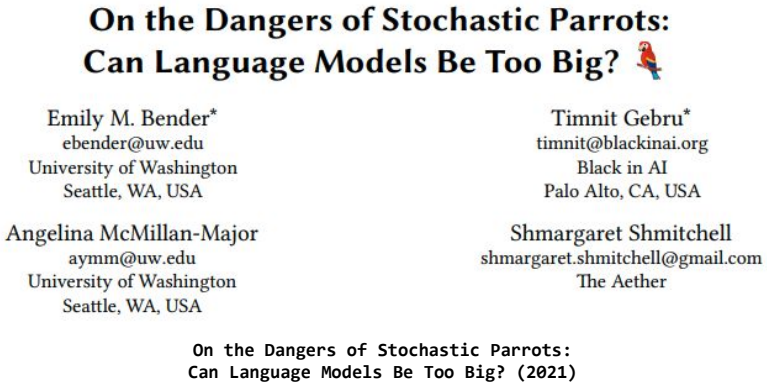


¿Qué es el lenguaje?

Desde un punto de vista de la **Lingüística**:

- El Lenguaje es un sistema de símbolos más reglas. Contempla semántica, sintaxis, y es pragmática.

- ¿Los Large Language Models (LLMs) conocen gramática o solo patrones?
  - ¿son loros estocásticos? (**Clase 7 y 8**)



On the Dangers of Stochastic Parrots: Can Language Models Be Too Big? 🦜

Emily M. Bender*
ebender@uw.edu
University of Washington
Seattle, WA, USA

Timnit Gebru*
timnit@blackinai.org
Black in AI
Palo Alto, CA, USA

Angelina McMillan-Major
aymm@uw.edu
University of Washington
Seattle, WA, USA

Shmargaret Shmitchell
shmargaret.shmitchell@gmail.com
The Aether

On the Dangers of Stochastic Parrots: Can Language Models Be Too Big? (2021)

¿Qué es el lenguaje?

Desde un punto de vista de la **Filosofía**:

- Ludwig Wittgenstein propone una idea clave:

"El significado de una palabra es su uso en el lenguaje."



- Esto rompe con la idea clásica de que las palabras tienen significado fijo.

- Por ejemplo la palabra "banco" puede significar:
  - Banco financiero
  - Banco para sentarse
  - Banco de peces

  El significado depende del contexto.

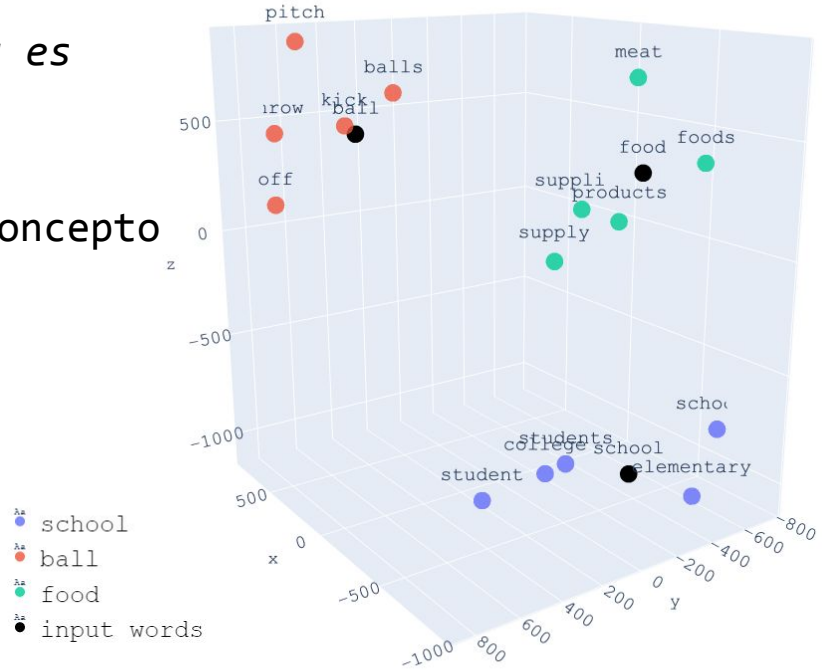
¿Qué es el lenguaje?

Desde un punto de vista de la **Filosofía**:

- Ludwig Wittgenstein propone una idea clave:

> *"El significado de una palabra es su uso en el lenguaje."*

- Esta idea está muy relacionada a un concepto llamado **embeddings** (Clase 2):



¿Qué es el Procesamiento de Lenguaje Natural?



El procesamiento de lenguaje natural (PLN o NLP) es el área de la Inteligencia Artificial que desarrolla modelos computacionales capaces de representar, procesar, comprender y generar lenguaje humano mediante métodos algorítmicos y estadísticos.

Desde IA, NLP implica cuatro cosas clave:

1.- Representación: Transformar lenguaje (texto o voz) en estructuras matemáticas

2.- Modelado: Construir funciones que capturen regularidades del lenguaje.

3.- Inferencia: Dado un input lingüístico, producir una salida coherente.

4.- Aprendizaje: Ajustar parámetros a partir de datos textuales masivos.

Manifestaciones del Lenguaje



Lenguaje hablado
En NLP: Speech Processing



Lenguaje escrito
En NLP: Desde N-Grams hasta **Transformers**



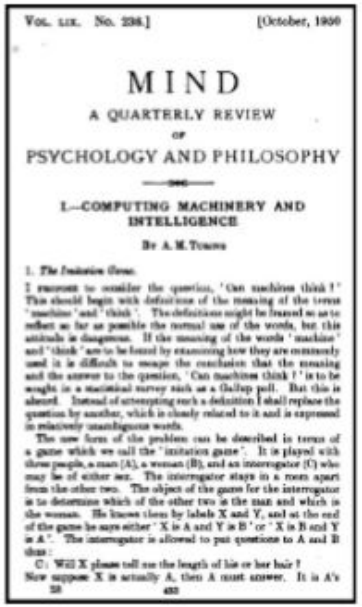
Lenguaje gestual
En NLP: Desde Sign Language Recognition hasta **MultiModalidad**



Lenguaje digital
En NLP: Desde Sentiment analysis hasta **Topic modeling**

Historia del NLP

Test de turing (1950)



Vol. LIX. No. 236.] [October, 1950

MIND

A QUARTERLY REVIEW

OF

PSYCHOLOGY AND PHILOSOPHY

I.—COMPUTING MACHINERY AND INTELLIGENCE

By A. M. Turing

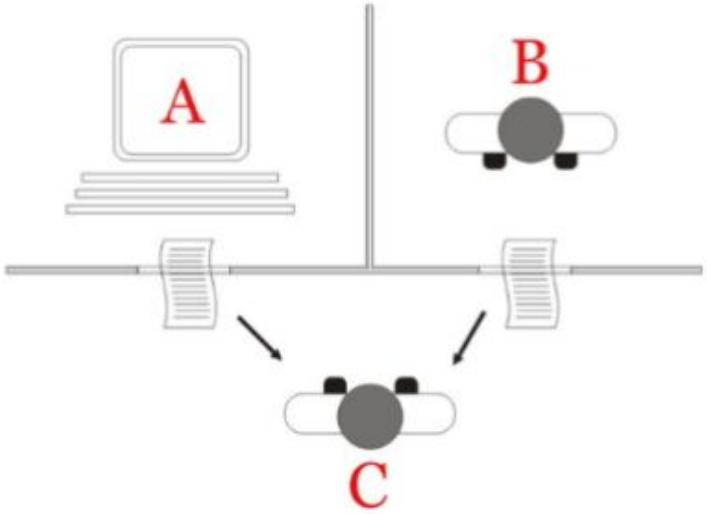
1. *The Imitation Game.*

I propose to consider the question, 'Can machines think?' This should begin with definitions of the meaning of the terms 'machine' and 'think'. The definitions might be framed so as to reflect so far as possible the normal use of the words, but this attitude is dangerous. If the meaning of the words 'machine' and 'think' are to be found by examining how they are commonly used it is difficult to escape the conclusion that the meaning and the answer to the question, 'Can machines think?' is to be sought in a statistical survey such as a Gallup poll. But this is absurd. Instead of attempting such a definition I shall replace the question by another, which is closely related to it and is expressed in relatively unambiguous words.

The new form of the problem can be described in terms of a game which we call the 'imitation game'. It is played with three people, a man (A), a woman (B), and an interrogator (C) who may be of either sex. The interrogator stays in a room apart from the other two. The object of the game for the interrogator is to determine which of the other two is the man and which is the woman. He knows them by labels X and Y, and at the end of the game he says either 'X is A and Y is B' or 'X is B and Y is A'. The interrogator is allowed to put questions to A and B thus:

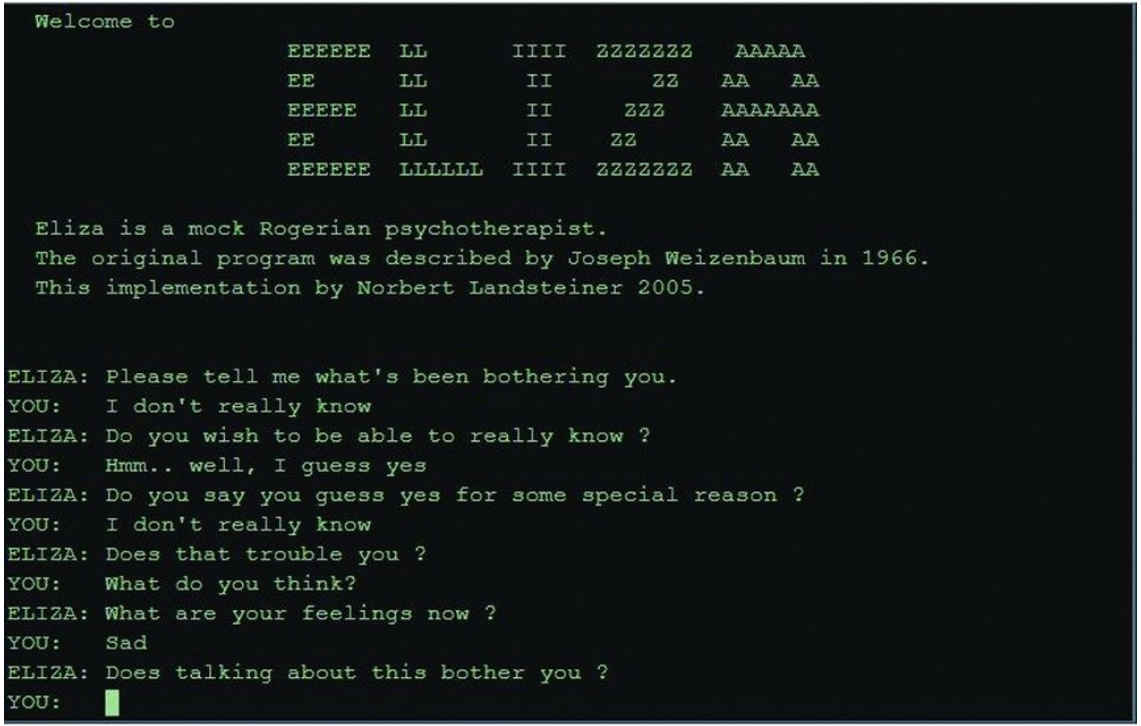
C: Will X please tell me the length of his or her hair?

Now suppose X is actually A, then A must answer. It is A's



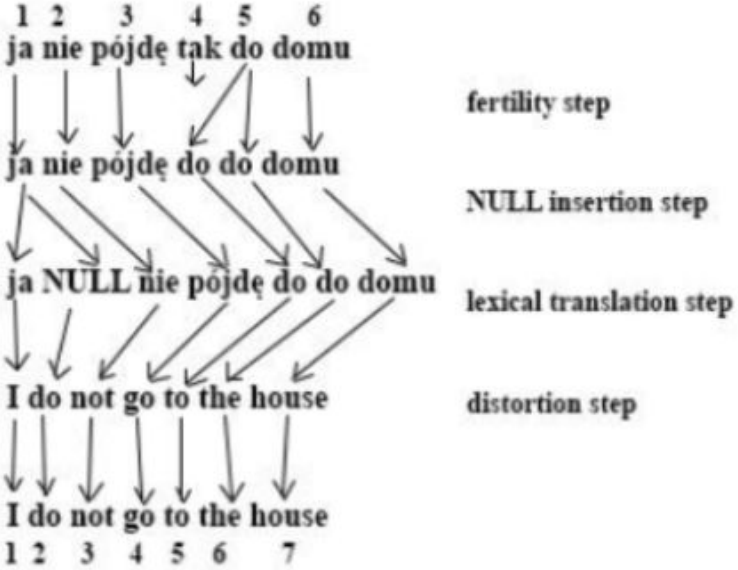
¿Puede una máquina hablar como si fuera un humano?

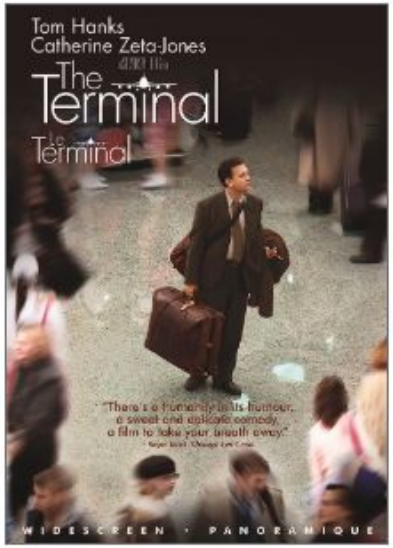
Eliza (1964) - Primer bot NLP



Se basaba en encontrar las palabras claves del texto y utilizarlas para formular una pregunta

Statistical Machine Translation (1990)

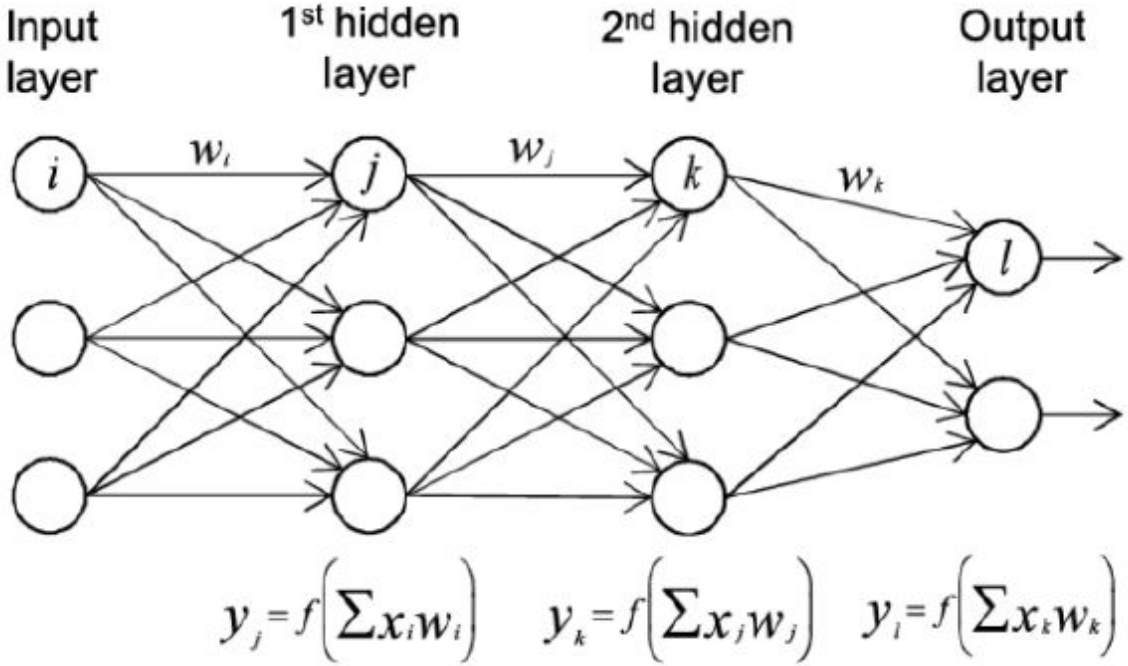




IBM introduce los SMT. Los cuales se basan en probabilidad para traducir texto de un idioma a otro.

Estos modelos son conocidos por su enfoque de alineación de palabras y su uso de datos paralelos para aprender traducciones.

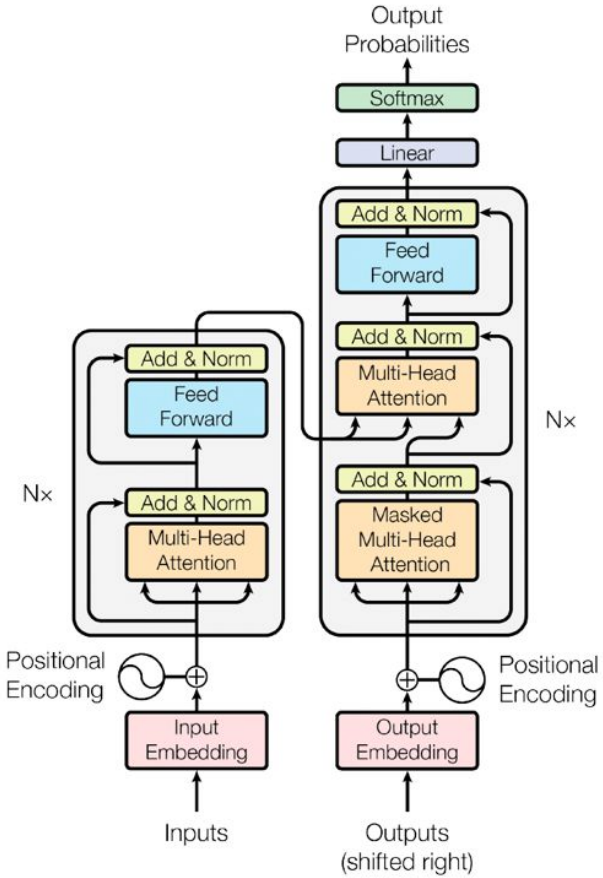
Deep Learning (2012 - ...)



Reduce esfuerzos manuales.

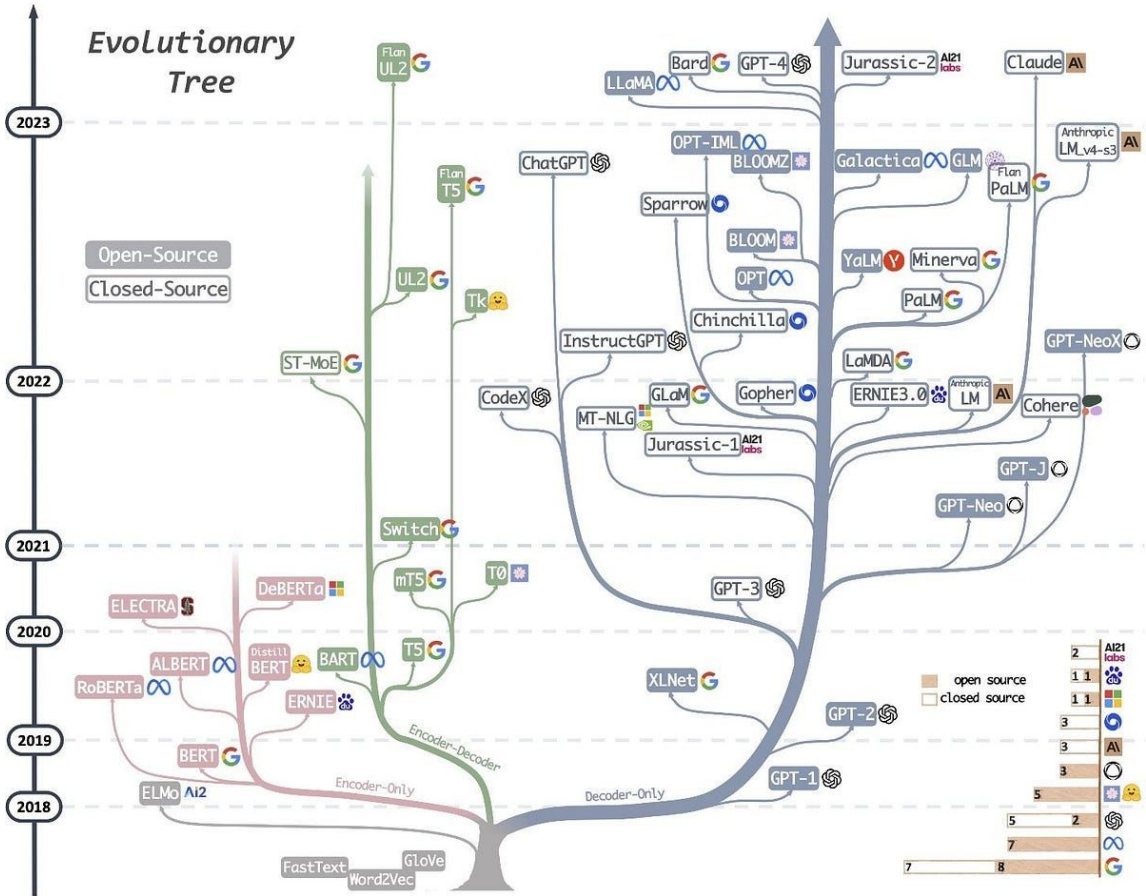
Tres ingredientes esenciales: Hardware, Data e Investigación

Transformer y Generative AI (2017 - ...)

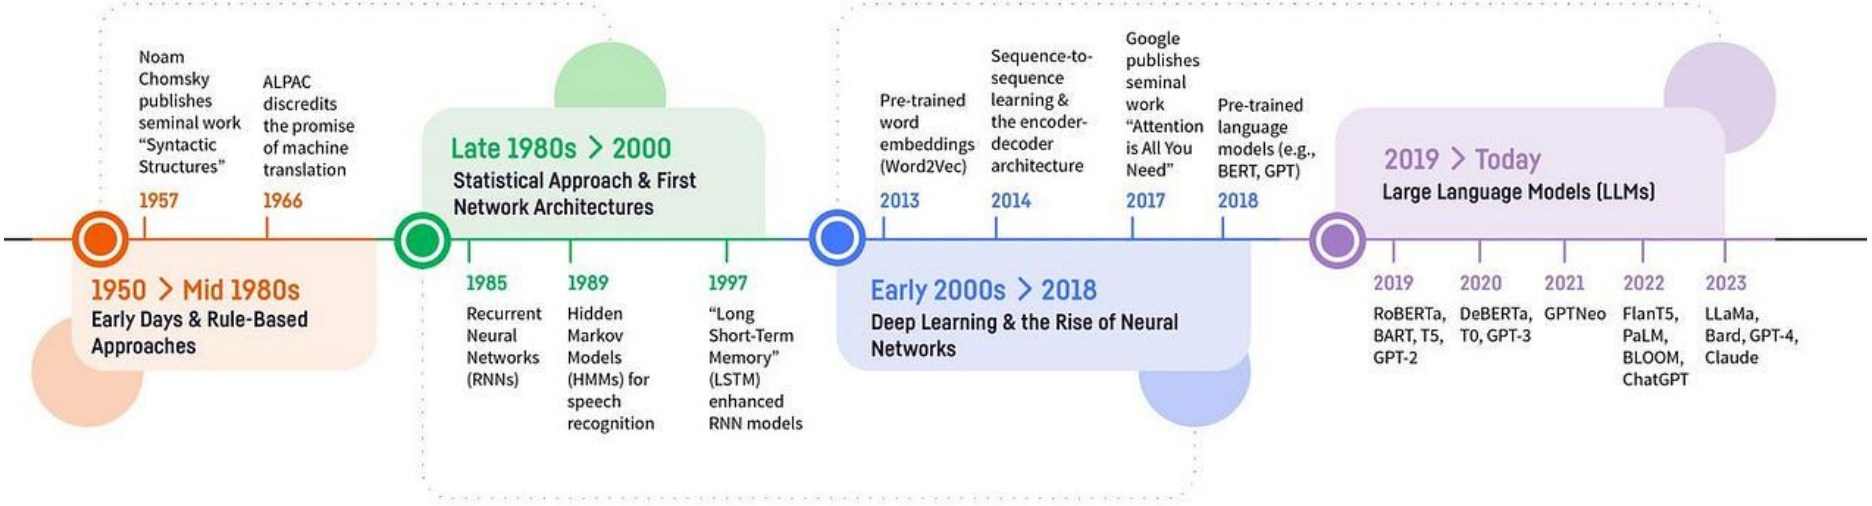


En 2017 se presenta el paper “Attention is All You Need” donde se propone la arquitectura Transformer, marcando así el inicio de Generative AI.

Generative AI (2017 - ...)



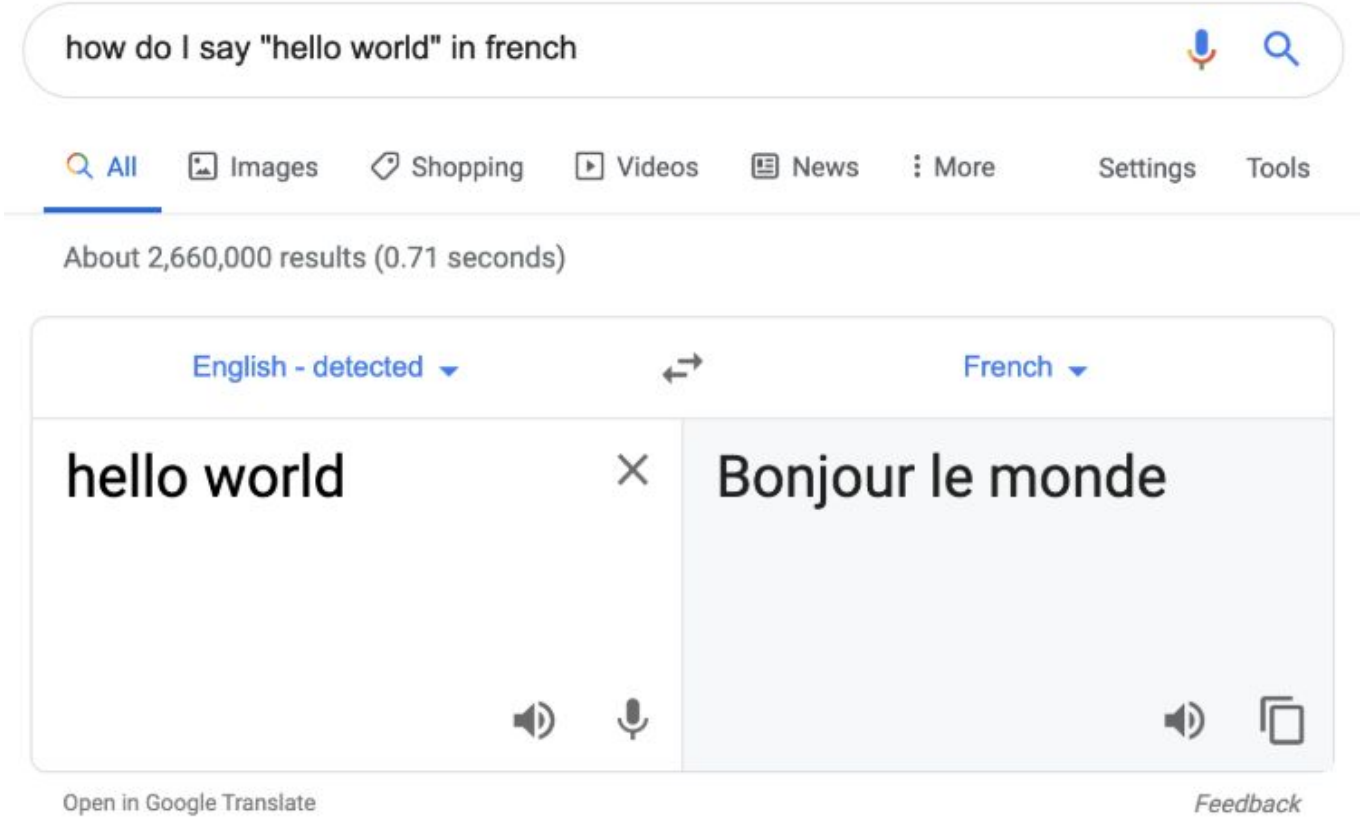
Resumen



Créditos: Dataiku

Aplicaciones de NLP

Machine Translation

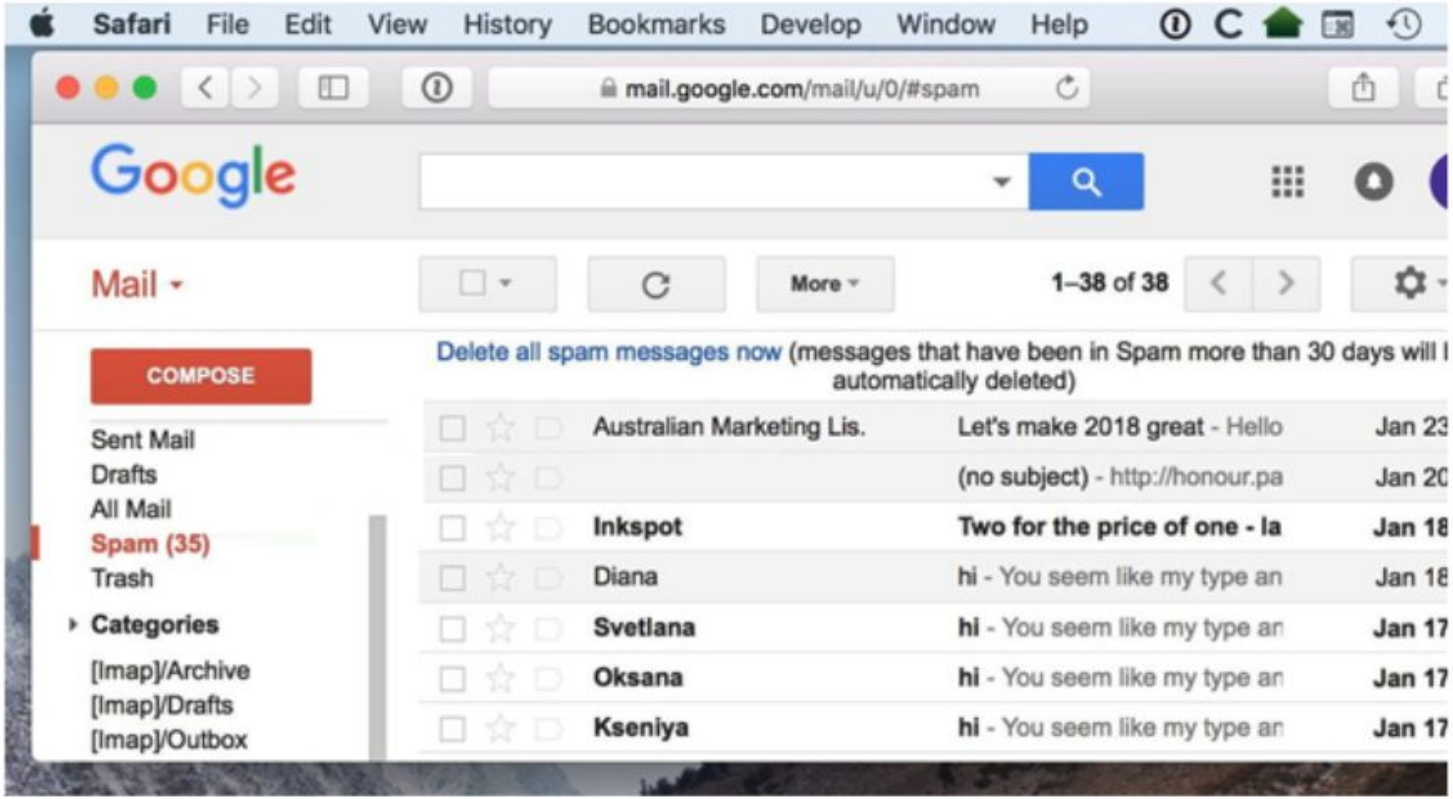


Asistentes de Voz





Clasificación de Texto

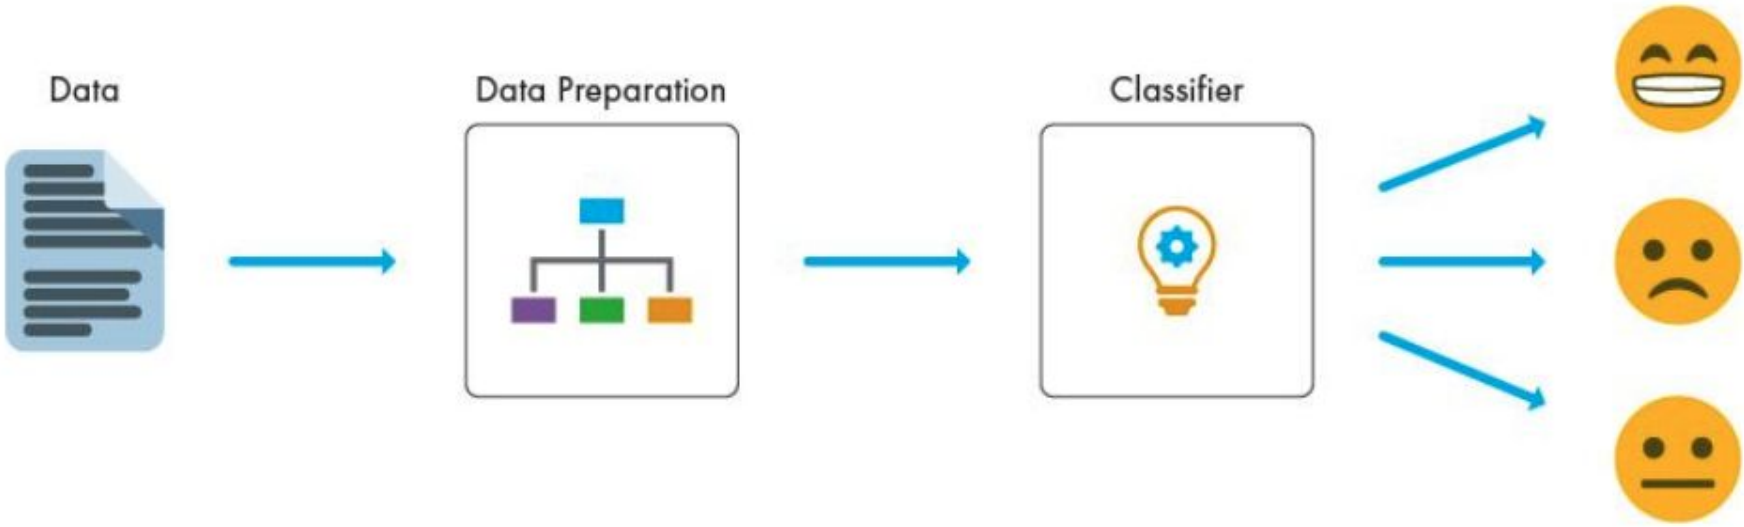


Chatbot

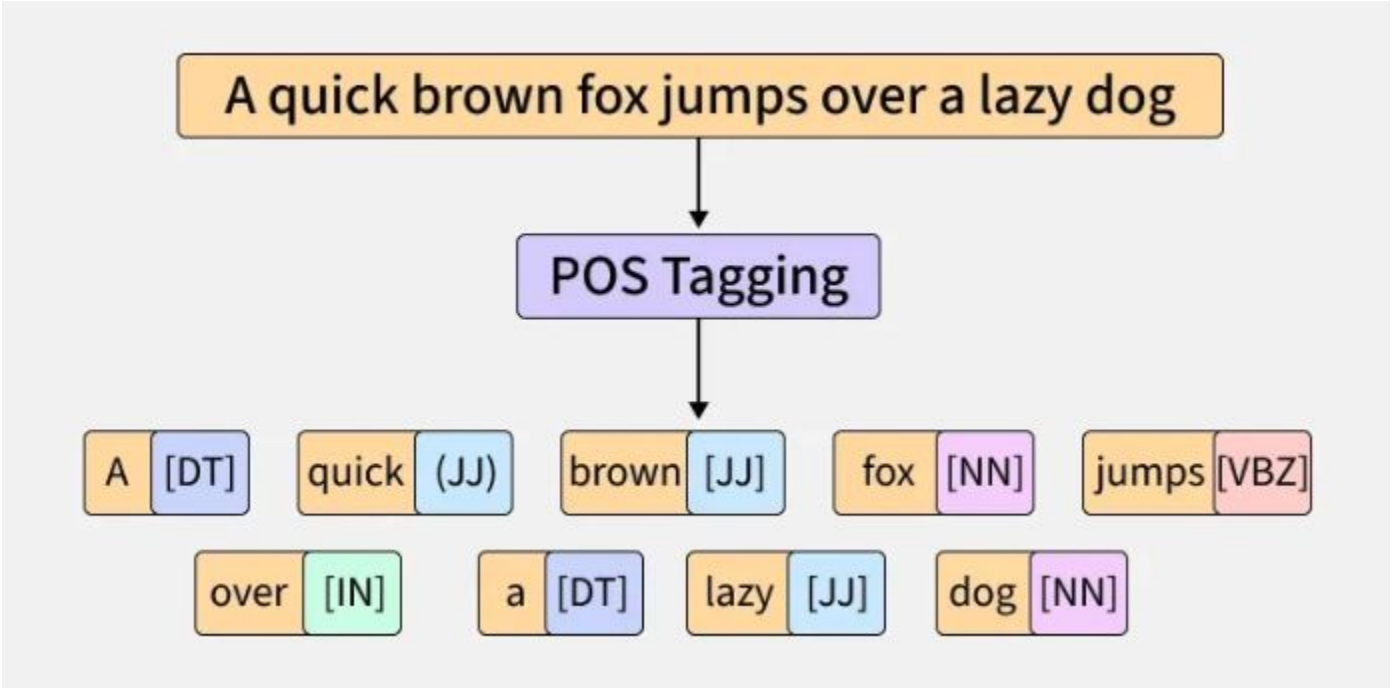

Hola!
hola simsimi
h
eres mi unico amigo
creeme que me gustaria dejarte en visto pero esta wea es mi pega

Tareas de NLP

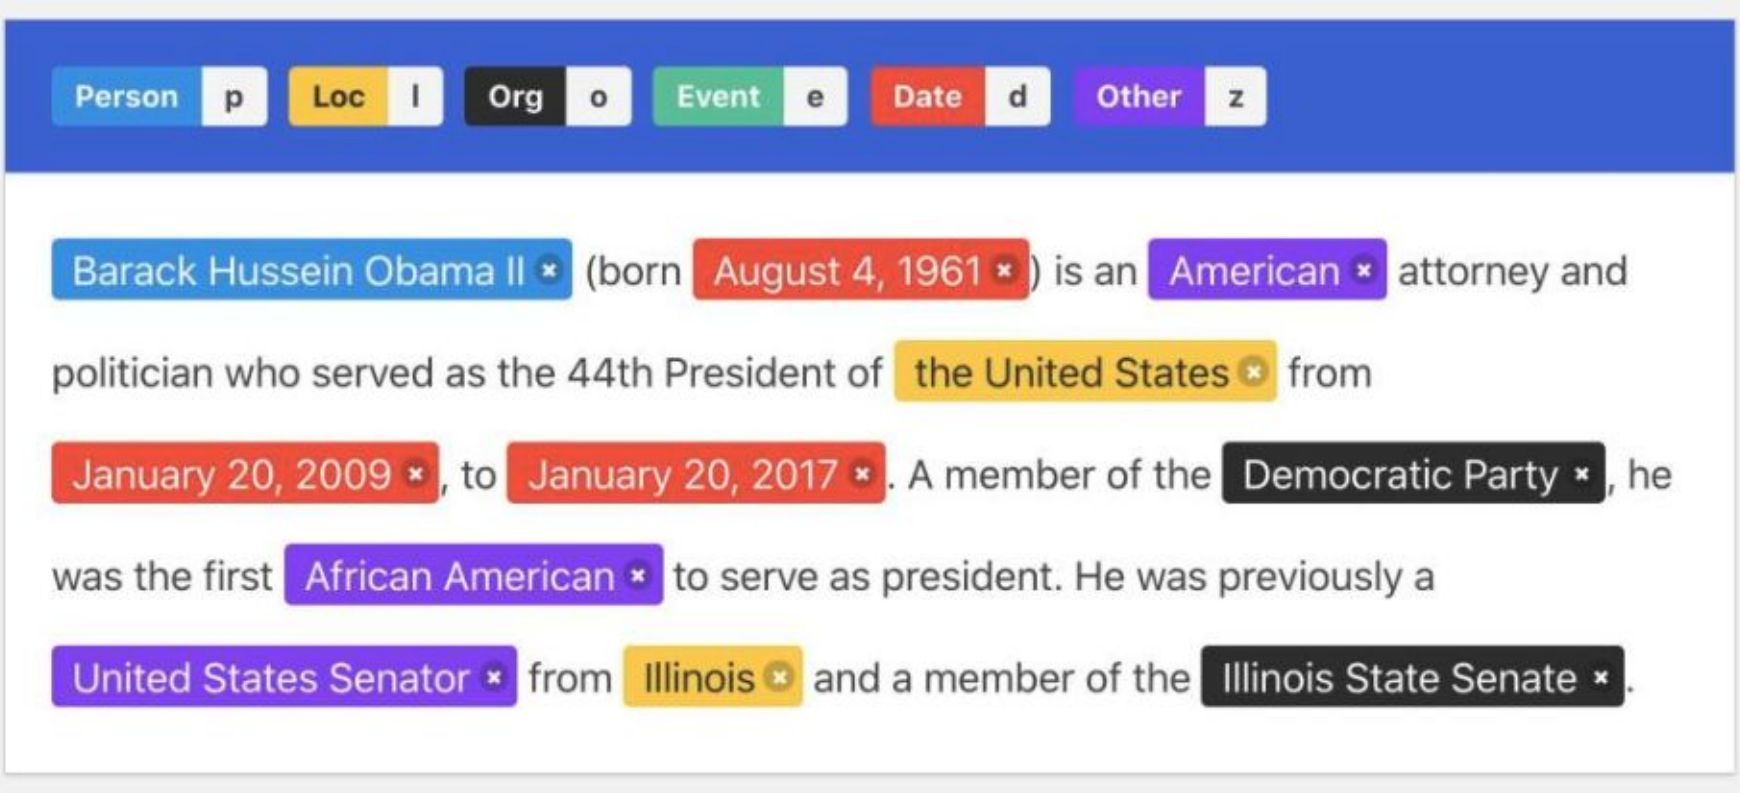
Clasificación



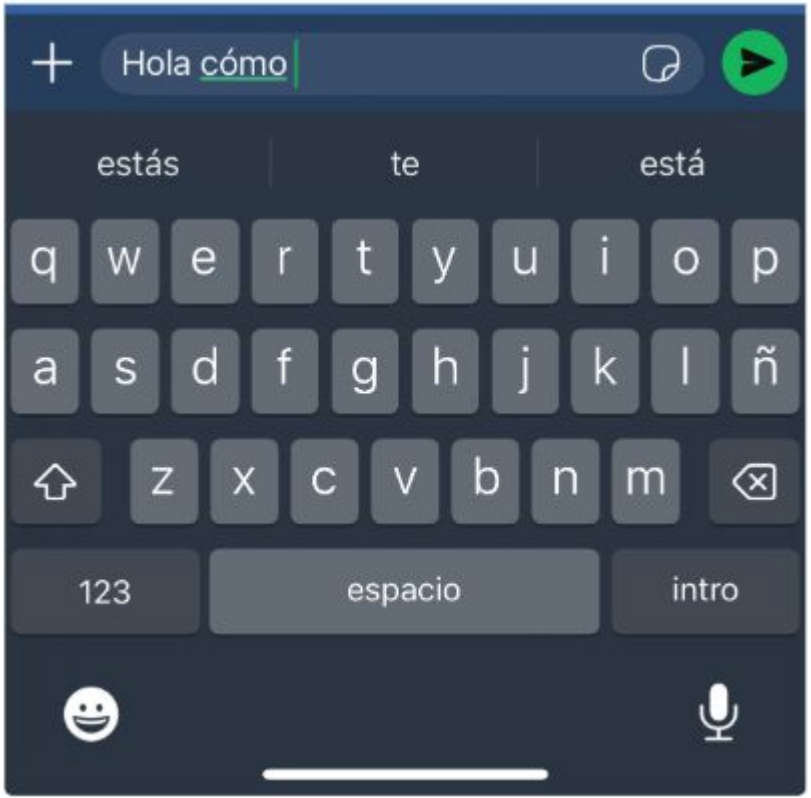
Tagging


A quick brown fox jumps over a lazy dog
POS Tagging
A [DT]
quick (JJ)
brown [JJ]
fox [NN]
jumps [VBZ]
over [IN]
a [DT]
lazy [JJ]
dog [NN]

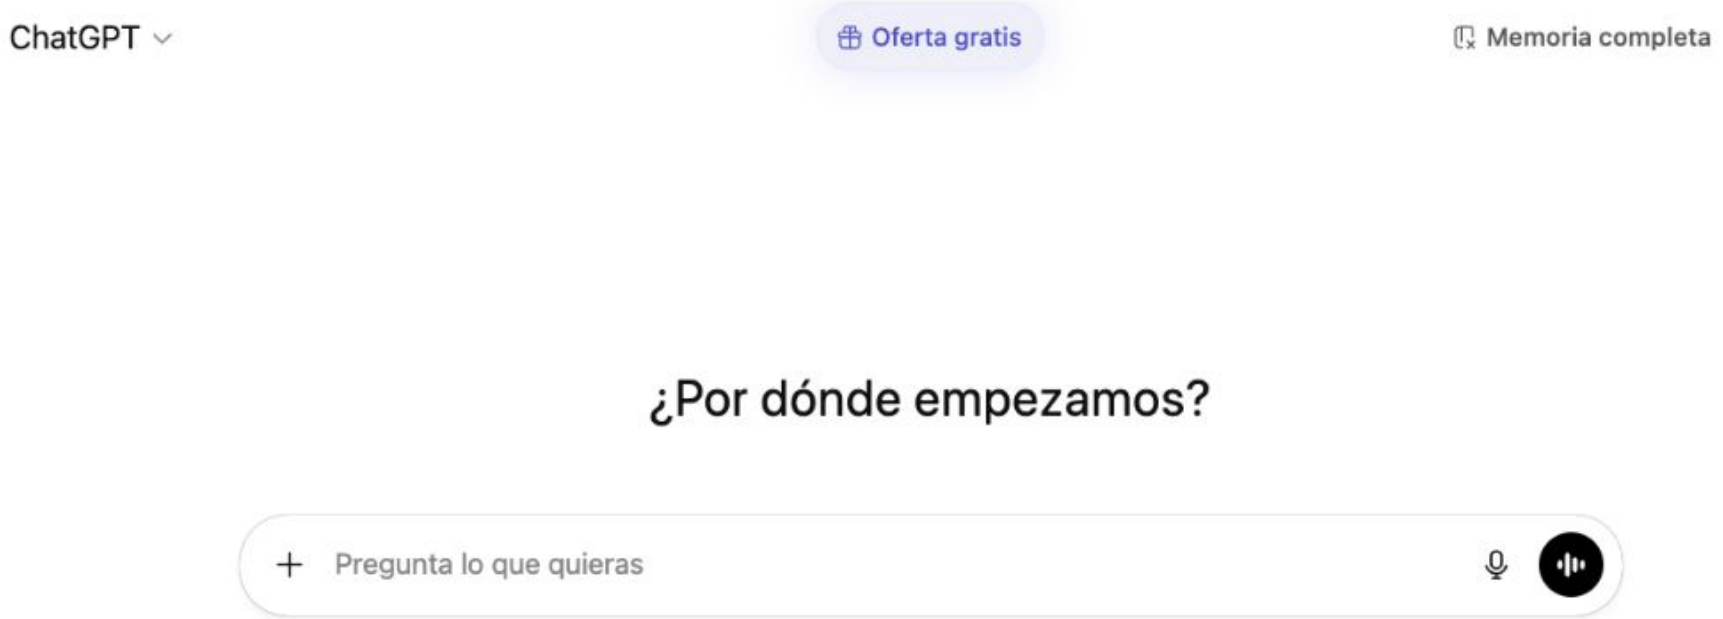
Tagging


Person p
Loc l
Org o
Event e
Date d
Other z
Barack Hussein Obama II (born August 4, 1961) is an American attorney and politician who served as the 44th President of the United States from January 20, 2009, to January 20, 2017. A member of the Democratic Party, he was the first African American to serve as president. He was previously a United States Senator from Illinois and a member of the Illinois State Senate.

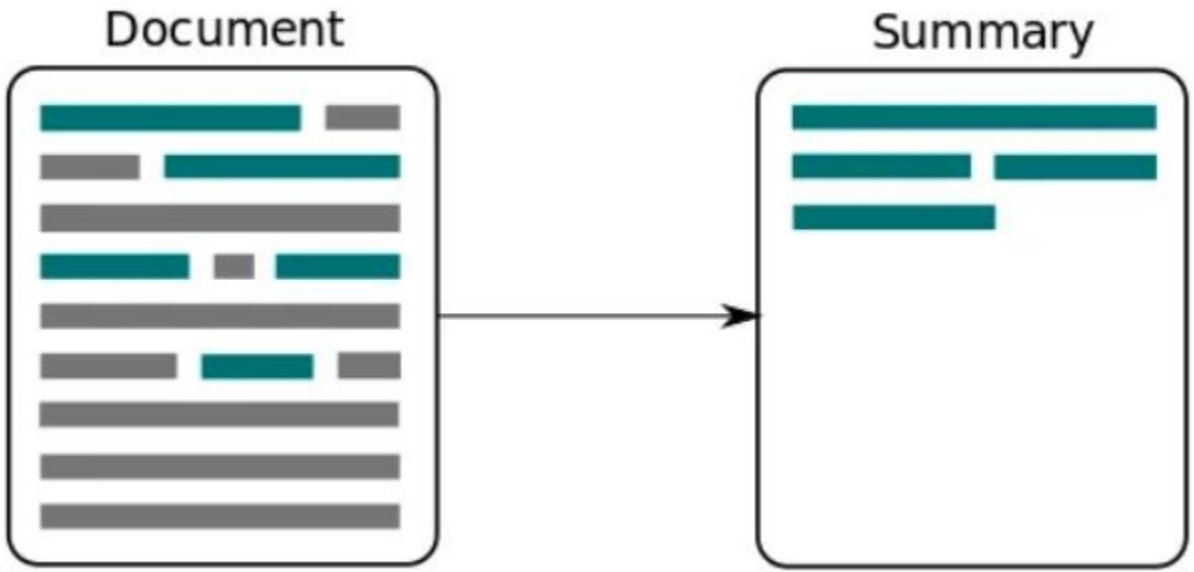
Autocompletado



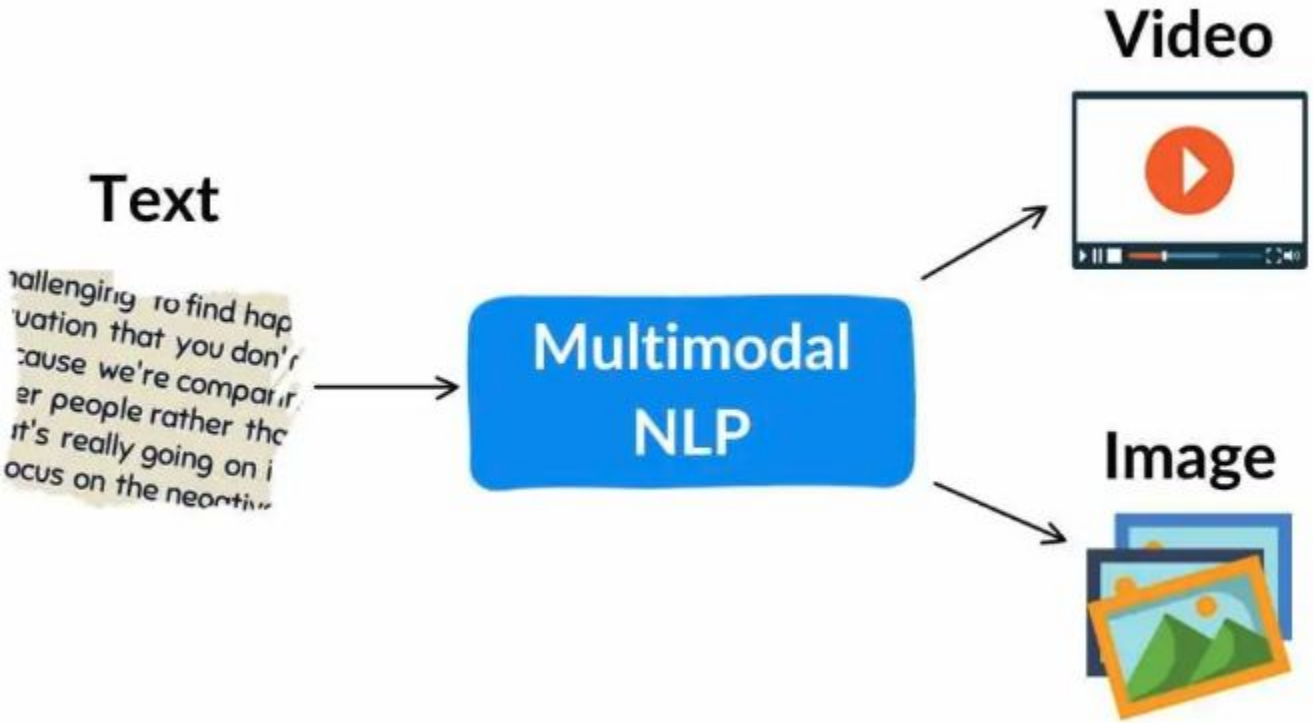
Generación de texto



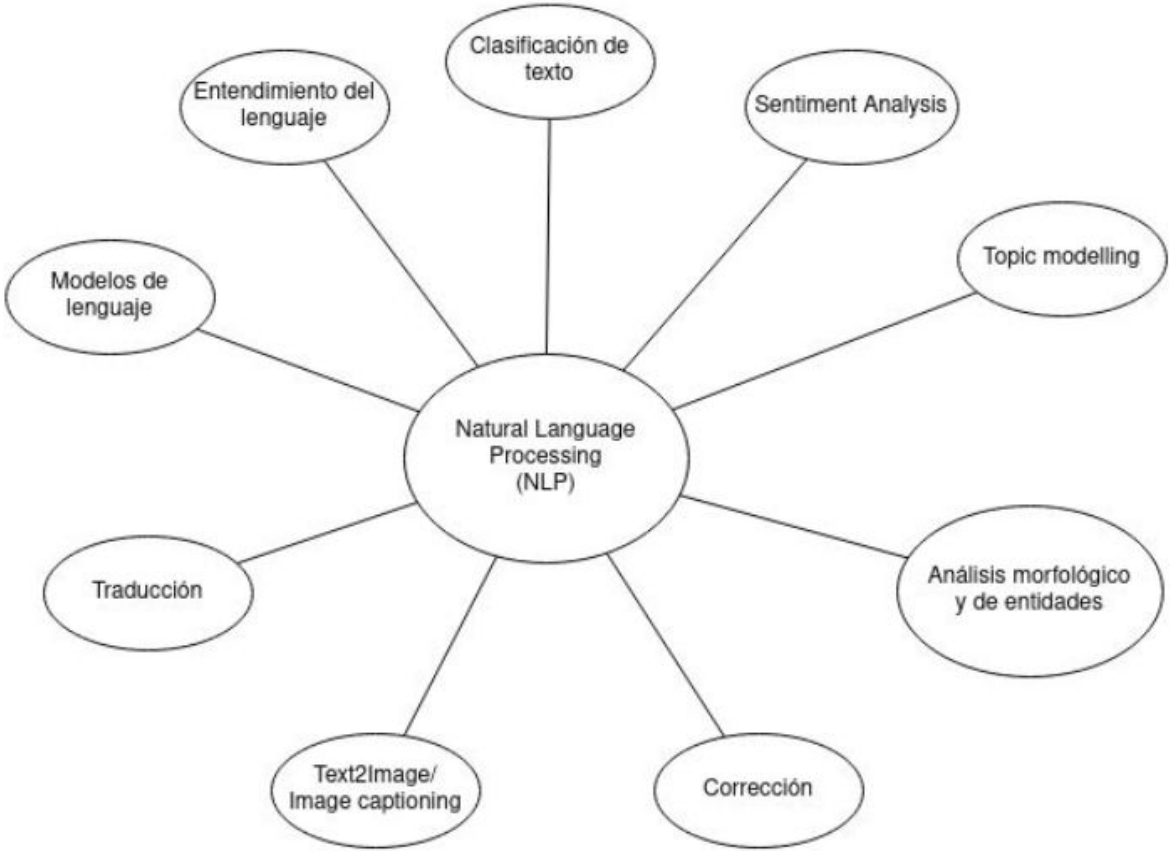
Summarization



Multimodalidad



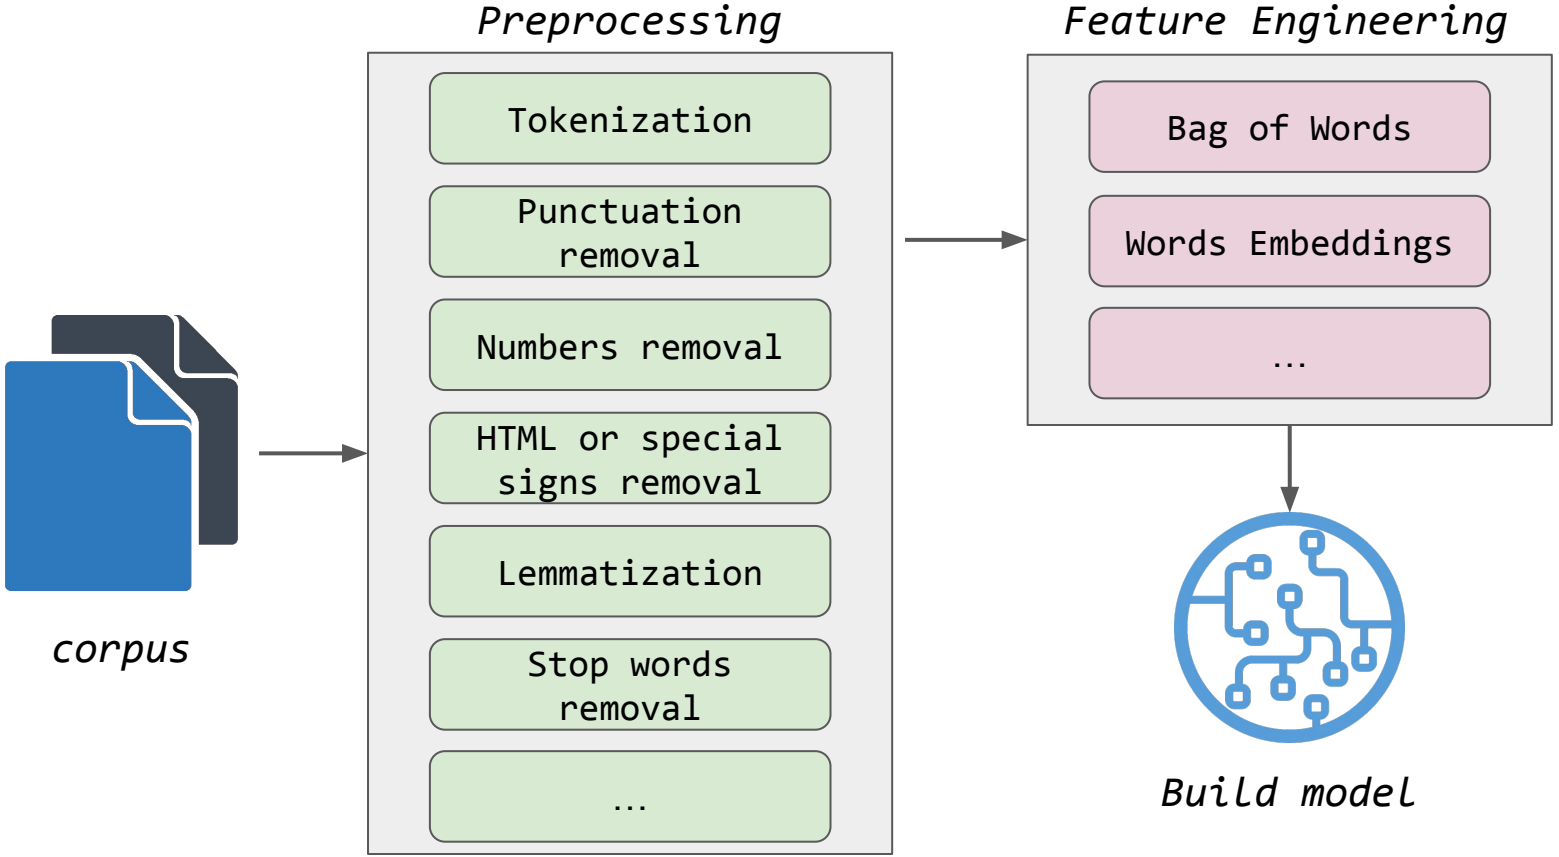
Tareas de NLP



Preprocesamiento de texto

Preprocesamiento de texto

LINK GLOSARIO



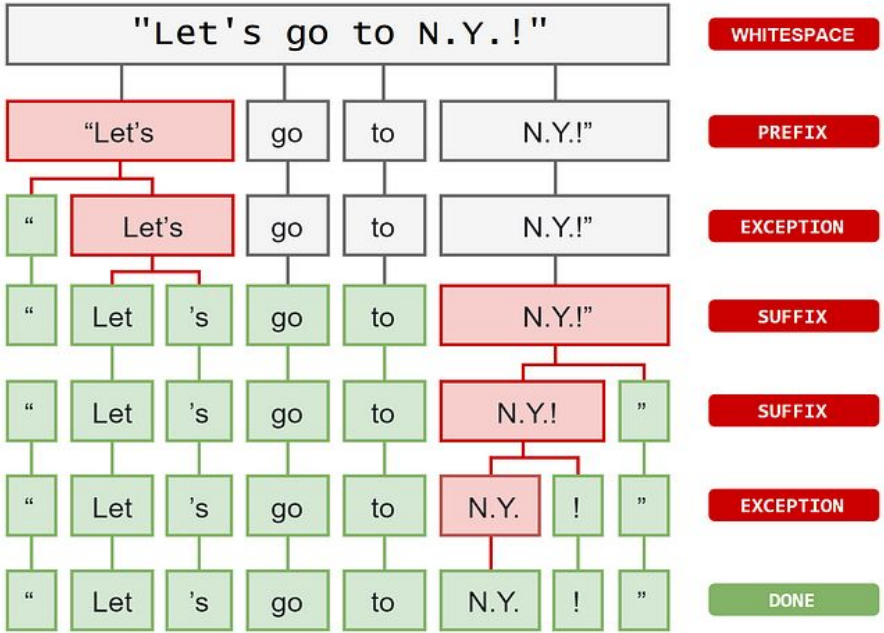
Normalización básica

- Lowercasing
- Eliminar signos de puntuación
- Quitar caracteres raros



Tokenization

Proceso en el cual una oración o documento es segmentado en términos individuales. Una vez finalizada la segmentación cada término único es referenciado mediante un token.



Tokenization



A primera vista parece que tokenizar es “solo hacer split”, pero tenemos los siguientes escenarios:

- abreviaturas como **D.C.**
- nombres compuestos como **New York**
- contracciones como **“doesn’t”** ó **“could't've”**
- nombres como **“SARS-Cov-2”** o **“R2-D2”**
- con idiomas como el **chino**, que no tienen espacios en blanco
- o idiomas como el **turco**, donde una sola palabra puede expresar tanta información como una oración completa

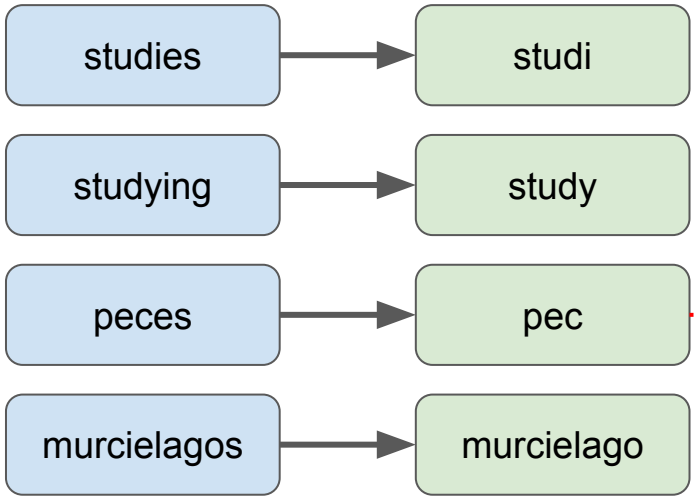
Tokenization



Stemming

Aplica reglas de eliminación de patrones recurrentes de la lengua. El resultado es una palabra truncada que no será necesariamente la raíz morfológica de la palabra.

Regla: Eliminar los sufijos



plural irregular

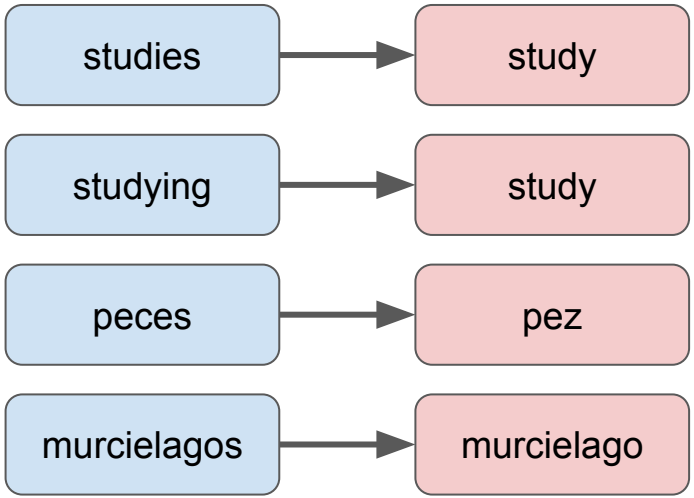
especimen, especímenes
régimen, regímenes

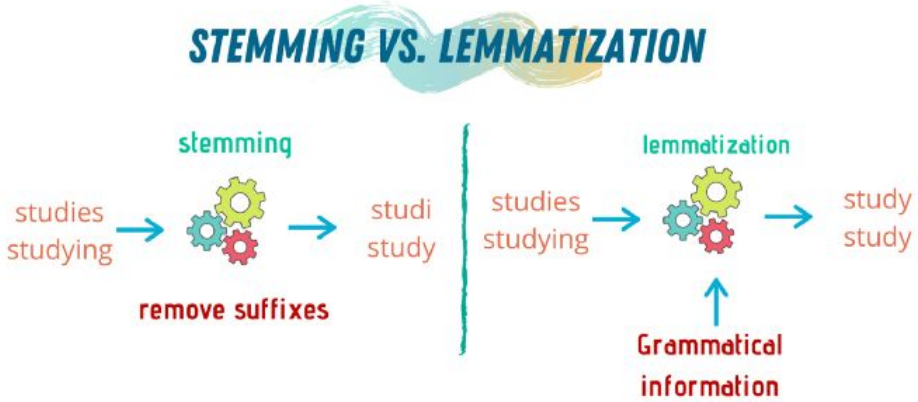
Stemming



Lematización (lemmatization)

Devuelve la raíz morfológica de una palabra. Para ello se necesita un diccionario del idioma con todas las declinaciones posibles de las palabras raíz.

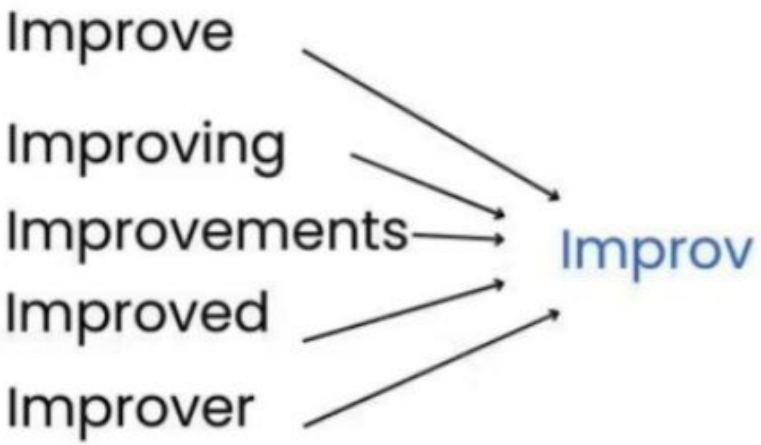




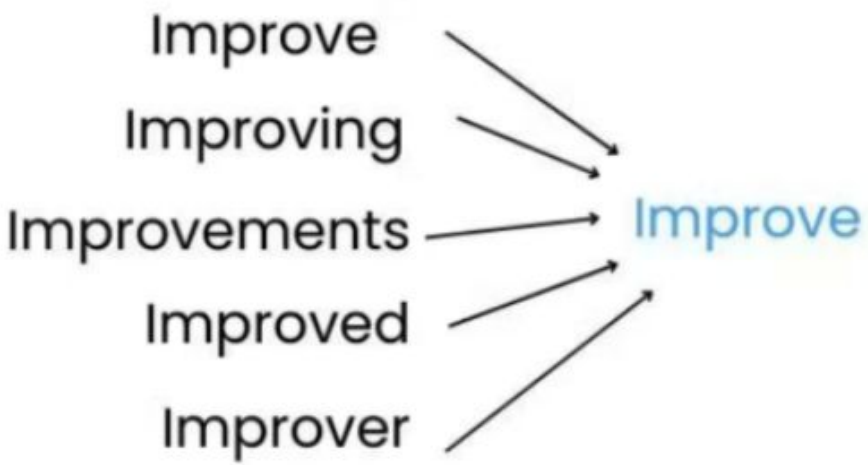
Lematización (lemmatization)



Stemming vs Lemmatization



Stemming



Lemmatization

Stemming vs Lemmatization



Stemming

Ventajas: Rápido y simple.

Desventajas: Puede producir raíces no válidas y perder precisión semántica.

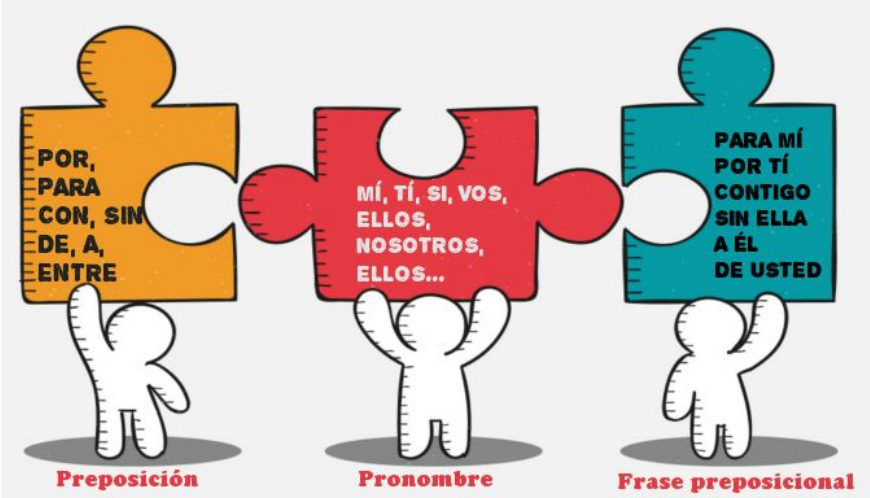
Lemmatization

Ventajas: Produce palabras válidas y mantiene la precisión semántica.

Desventajas: Puede ser más lenta y requiere recursos adicionales (como WordNet).

Stop words

Palabras que no aportan valor al significado de una oración ya que son muy frecuentes o comunes en el lenguaje



*Argentina, oficialmente, República Argentina, es **un** país soberano **de** América **del** Sur, ubicado **en el** extremo sur **y** sudeste **de** dicho subcontinente. Adopta **la** forma **de** gobierno republicana, democrática, representativa **y** federal.*

Argentina, oficialmente, República Argentina, es país soberano América Sur, ubicado extremo sur sudeste dicho subcontinente. Adopta forma gobierno republicana, democrática, representativa federal.

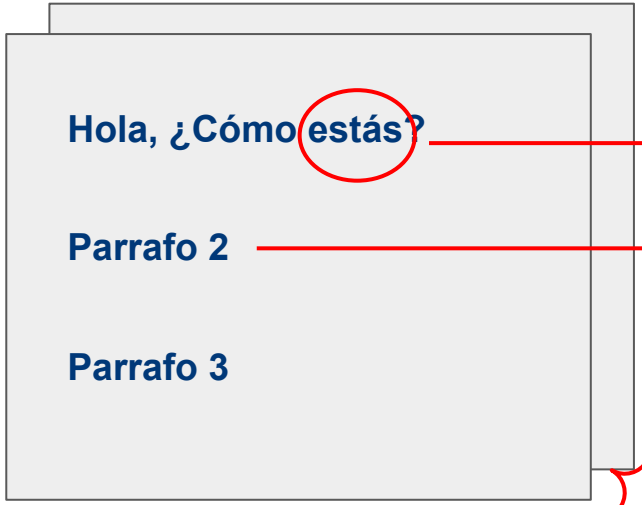
Practiquemos lo visto hasta ahora



Vectorización de Texto

Vectorización de texto

LINK GLOSARIO



Término t: palabra/símbolo "t" del documento

Document: su largo es variable, normalmente una sentencia/oración/párrafo.

Corpus: conjunto de documentos, forman todo el vocabulario.

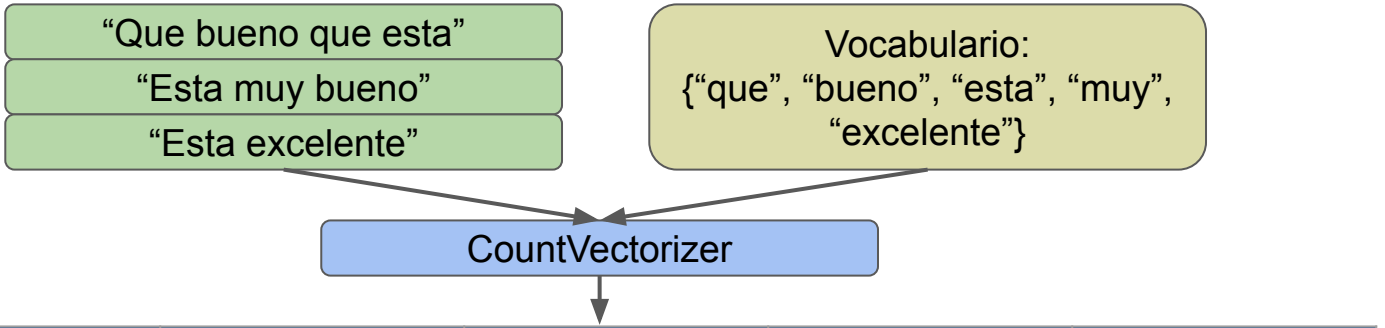
No podemos ingresar texto a una red
¿Cómo transformamos palabras a números?

vectorización →

Vectores de palabras/documentos

Vectores de frecuencia/conteo

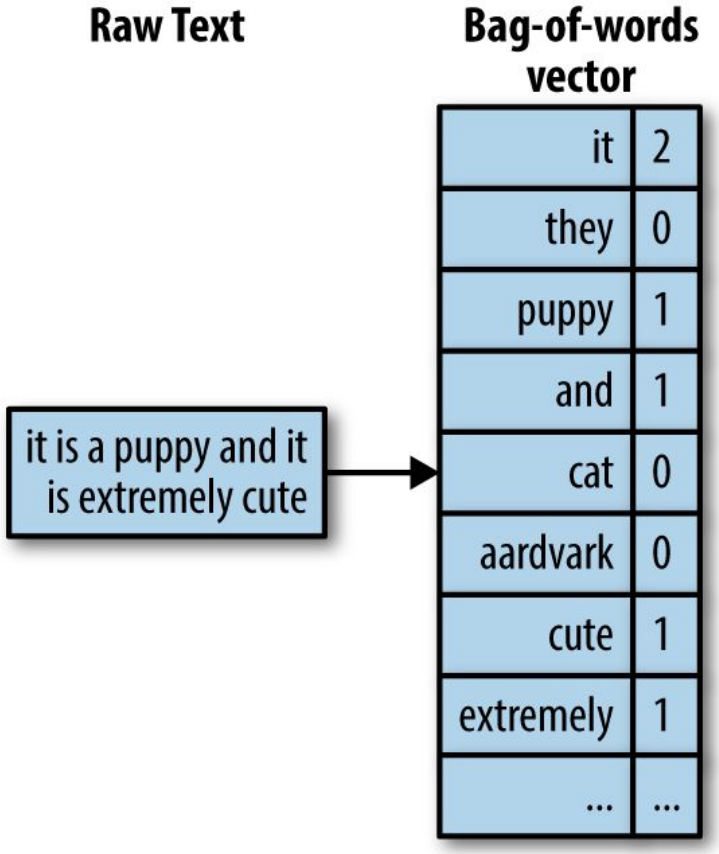
"Por cada documento en el corpus se calcula un vector que representa cuántas veces cada palabra del vocabulario aparece en ese documento"



que	bueno	esta	muy	excelente
2	1	1	0	0
0	1	1	1	0
0	0	1	0	1

Los vectores tienen el tamaño del vocabulario

Bolsa de palabras (BOW)



Bag of Words representa un documento mediante un vector basado en la presencia o frecuencia de palabras del vocabulario, ignorando el orden en el que aparecen.

Bolsa de palabras (BOW)

Corpus:

The dog is happy. The child makes the dog happy. The dog makes the child happy

↓

Tokenization:

D1: [The] [dog] [is] [happy]
D2: [The] [child] [makes] [the] [dog] [happy]
D3: [The] [dog] [makes] [the] [child] [happy]

↓

Documents	Counting word frequencies
D1	the: 1, dog: 1, is: 1, happy: 1
D2	the: 2, dog: 1, makes: 1, child: 1, happy: 1
D3	the: 2, child: 1, makes: 1, dog: 1, happy: 1

↓

Encode	child	dog	happy	is	makes	the	BoW Vector representations
D1	0	1	1	1	0	1	[0,1,1,1,0,1]
D2	1	1	1	0	1	2	[1,1,1,0,1,2]
D3	1	1	1	0	1	2	[1,1,1,0,1,2]

Bag of Words representa un documento mediante un vector basado en la presencia o frecuencia de palabras del vocabulario, **ignorando el orden en el que aparecen.**

Bolsa de palabras (BOW)

Document D1	*The child makes the dog happy* the: 2, dog: 1, makes: 1, child: 1, happy: 1
Document D2	*The dog makes the child happy* the: 2, child: 1, makes: 1, dog: 1, happy: 1

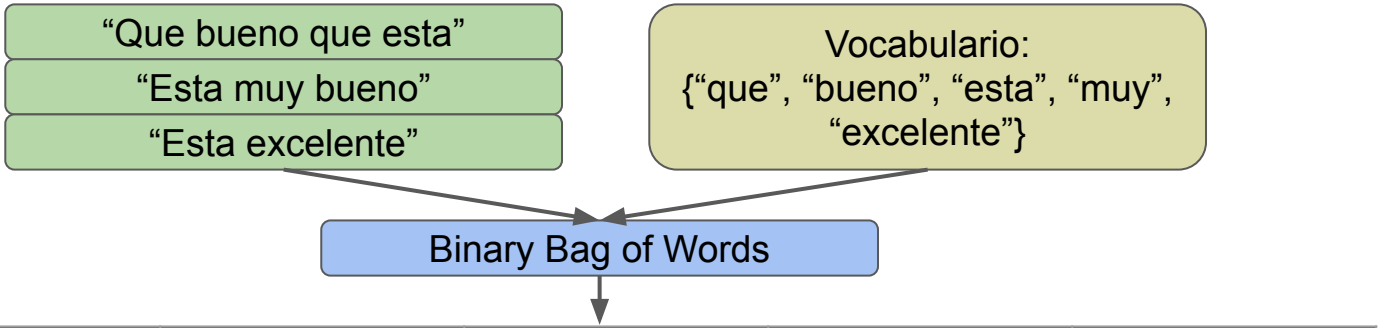
↓

	child	dog	happy	makes	the	BoW Vector representations
D1	1	1	1	1	2	[1,1,1,1,2]
D2	1	1	1	1	2	[1,1,1,1,2]

Bag of Words representa un documento mediante un vector basado en la presencia o frecuencia de palabras del vocabulario, **ignorando el orden en el que aparecen.**

Vectores Binary Bag of Words

"Por cada documento en el corpus se calcula un vector que representa si cada palabra del vocabulario aparece o no en ese documento"

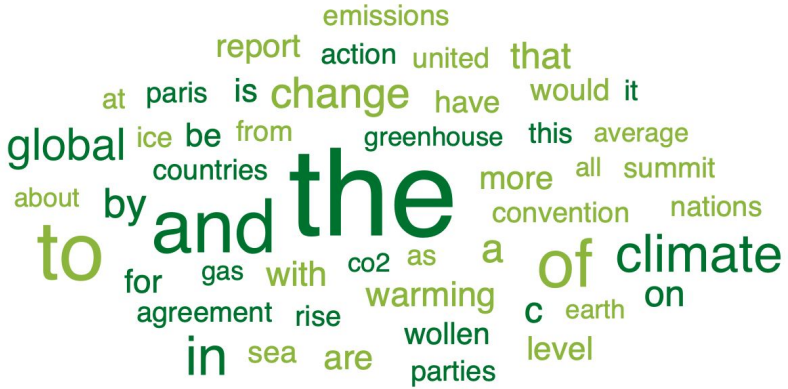


que	bueno	esta	muy	excelente
1	1	1	0	0
0	1	1	1	0
0	0	1	0	1

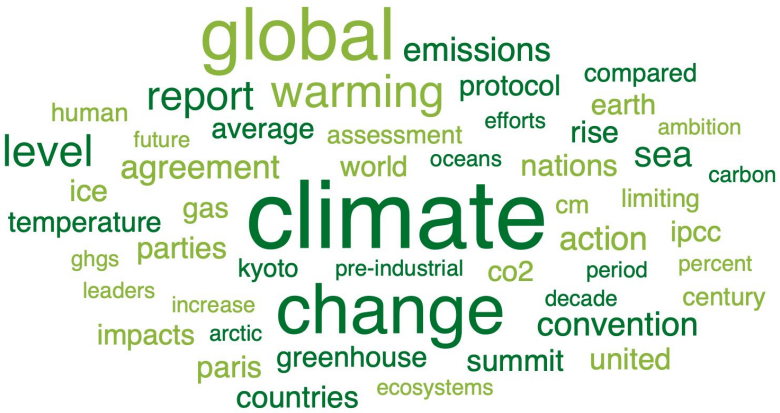
Stop words

Analizar un texto relacionado con calentamiento global (global climate)

Texto con Stop Words



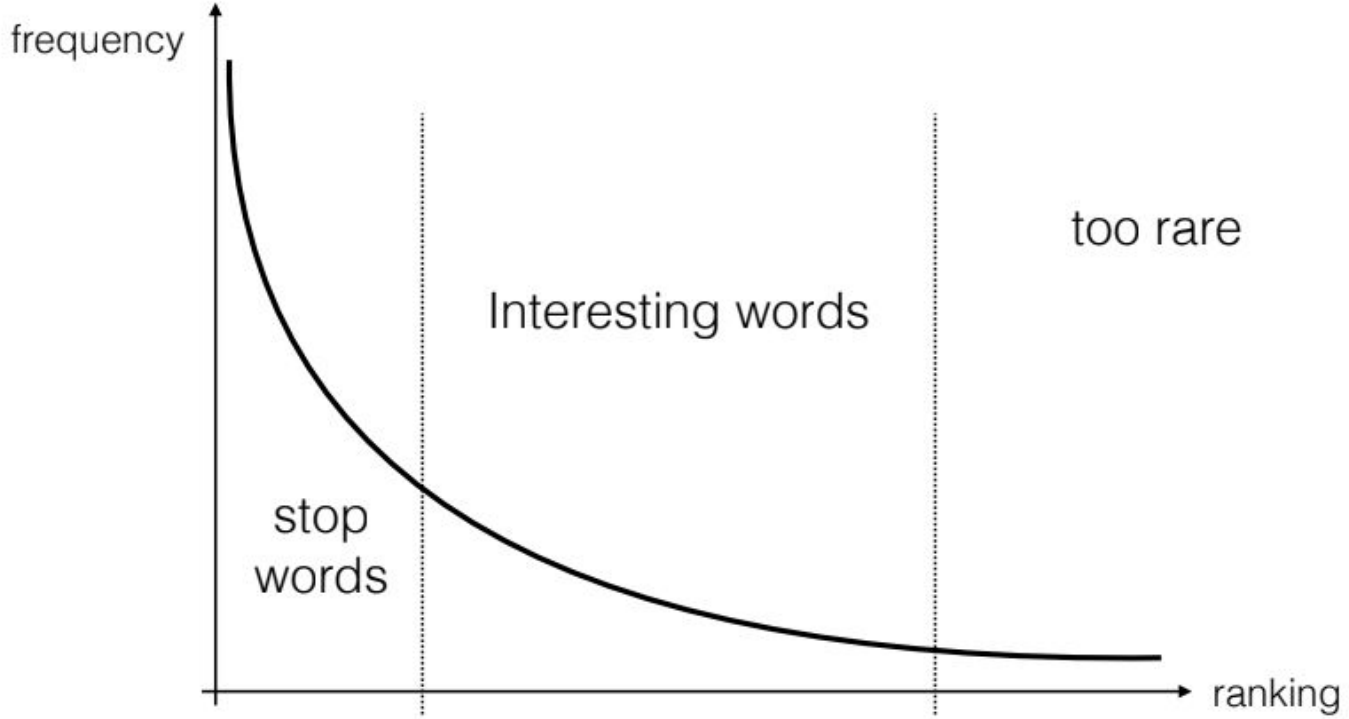
Texto sin Stop Words



Las Stop Words pueden depender del contexto del corpus.

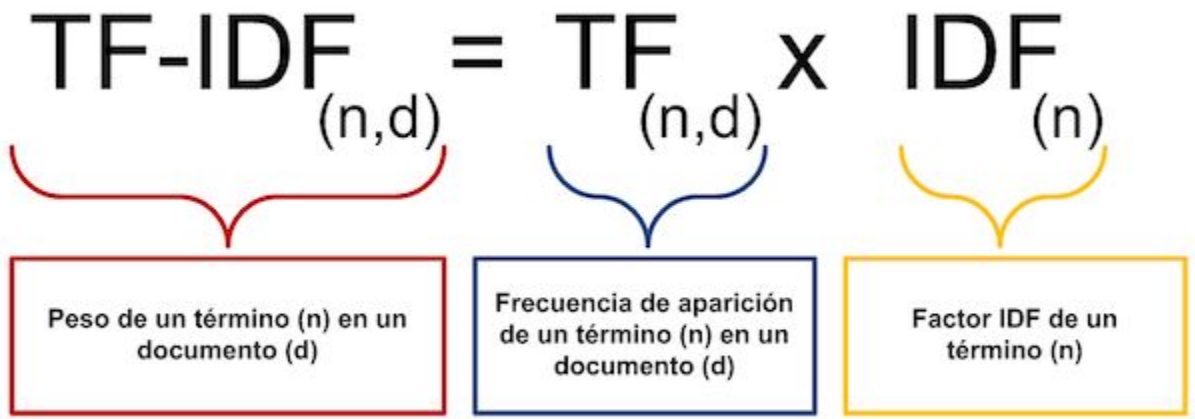
Stop words

Zipf's Law



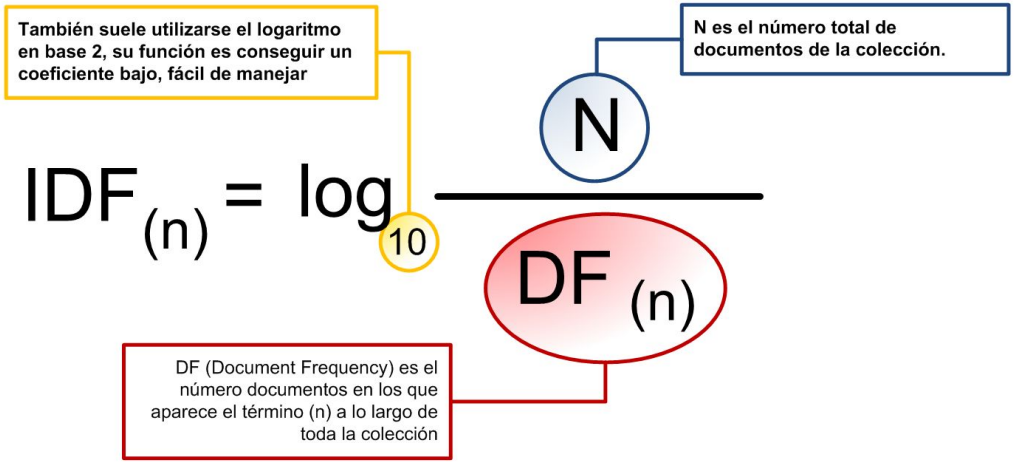
TF-IDF (Term frequency-Inverse document frequency)

Se utiliza como indicador de cuán importante es una palabra (término) en un documento.



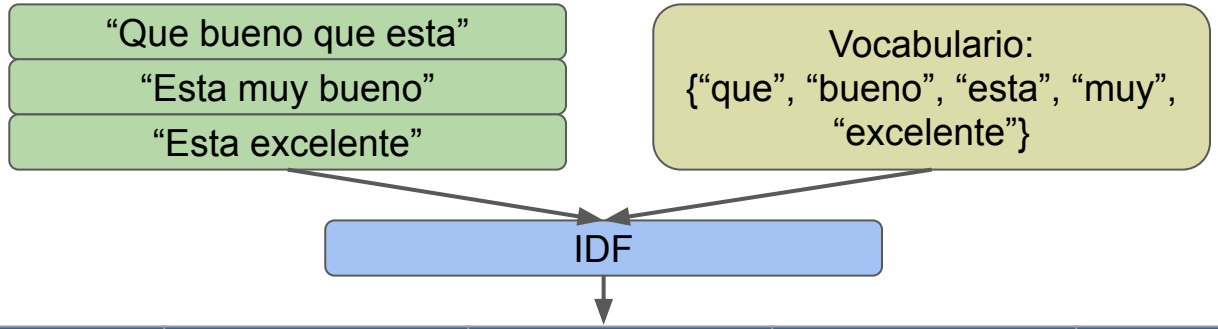
Vector IDF (Inverse Document Frequency)

"Proporción de documentos en el corpus que poseen el término"



Si el término aparece en todos los documentos el IDF será cero (es popular y por lo tanto aporta poco valor)

Vector IDF



que	bueno	esta	muy	excelente
log(3/1)	log(3/2)	log(3/3)	log(3/1)	log(3/1)

que	bueno	esta	muy	excelente
0.477	0.176	0	0.477	0.477

Se obtiene como la división de la cantidad de documentos sobre la suma en axis=0 (vertical) del CountVectorizer.

Vector TF-IDF



"Que bueno que esta"
"Esta muy bueno"
"Esta excelente"

Vocabulario:
{"que", "bueno", "esta", "muy", "excelente"}

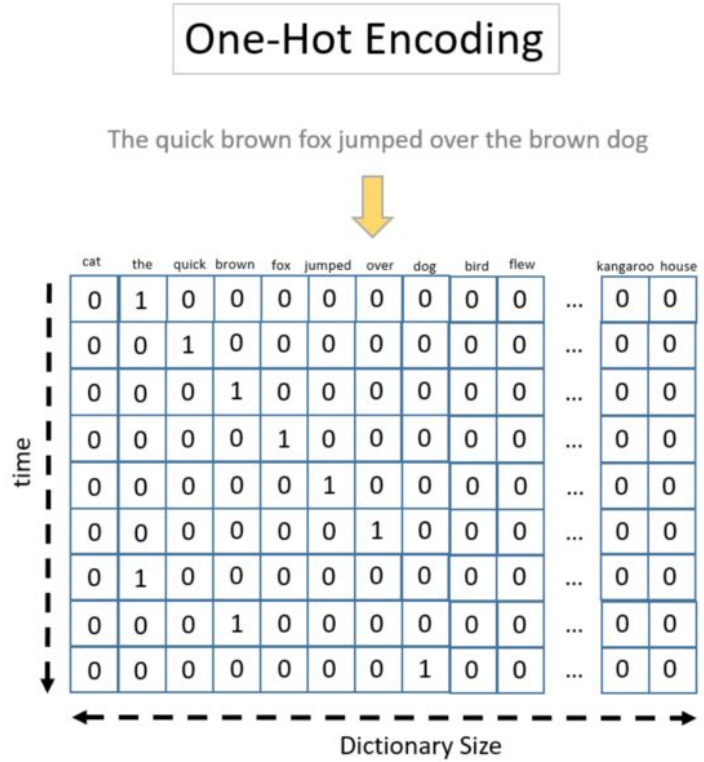
IDF

que	bueno	esta	muy	excelente
log(3/1)	log(3/2)	log(3/3)	log(3/1)	log(3/1)

TF-IDF

que	bueno	esta	muy	excelente
2 * log(3/1)	1 * log(3/2)	1 * log(3/3)	0 * log(3/1)	0 * log(3/1)
0 * log(3/1)	1 * log(3/2)	1 * log(3/3)	1 * log(3/1)	0 * log(3/1)
0 * log(3/1)	0 * log(3/2)	1 * log(3/3)	0 * log(3/1)	1 * log(3/1)

Esparsidad de los vectores de conteos



¡El idioma inglés tiene más de 180.000 palabras en su vocabulario en uso!

¡La representación es sumamente rala! (poco densa)

No estamos aprovechando eficientemente la dimensionalidad del espacio de vectores.

Similitud entre documentos

¿Cómo medimos qué tan parecidos son dos textos o palabras comparando el significado de sus vectores?

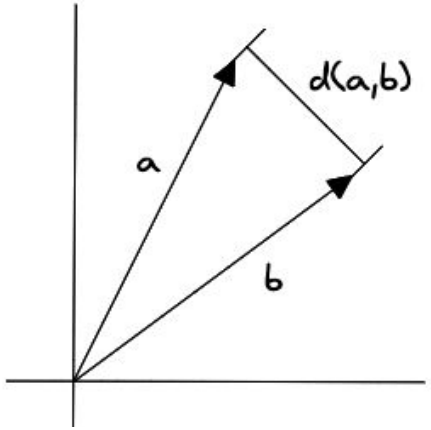
En NLP clásico (TF-IDF, BoW):

- Palabras frecuentes pueden tener vectores con mayor norma.

Si usamos Euclidiana:

- Documentos largos parecen más lejos
- Palabras frecuentes dominan

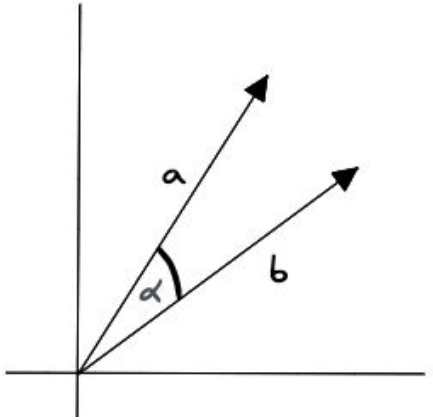
Coseno normaliza eso.



Distancia Euclideana

$$d(x, y) = \sqrt{\sum_{i=1}^{n}(y_i - x_i)^2}$$

Mide distancia absoluta en el espacio. Depende fuertemente de la magnitud.



Similitud Coseno

$$\cos(\theta) = \frac{\mathbf{A} \cdot \mathbf{B}}{\|\mathbf{A}\|\|\mathbf{B}\|}$$

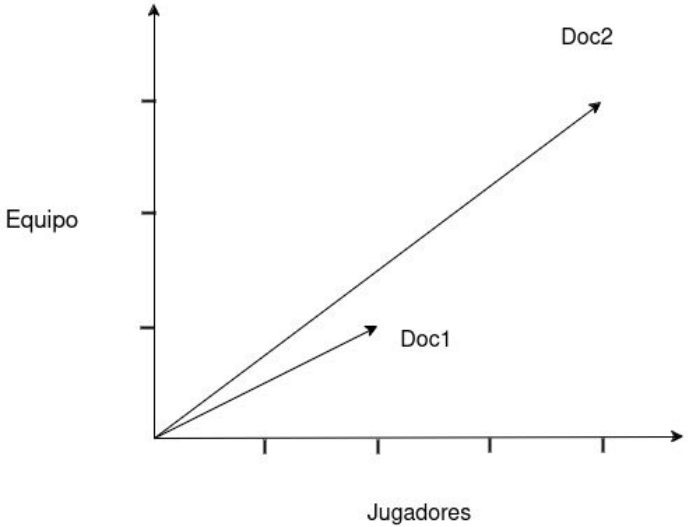
Mide el ángulo entre vectores. Ignora la magnitud y compara orientación.

Relación entre textos: Similitud coseno

Forma de medir qué tan "cerca" está una frase de otra, pero no por su longitud, sino por su **dirección**.

Doc1 *"Cada equipo en el campo tiene hasta once jugadores…"*

Doc2 *"... el equipo Argentino presentó a todos sus jugadores titulares…*



Similitud coseno = 1 → los vectores tienen la misma dirección.
Similitud coseno = 0 → los vectores son ortogonales.
Similitud coseno = -1 → los vectores apuntan en sentido contrario.

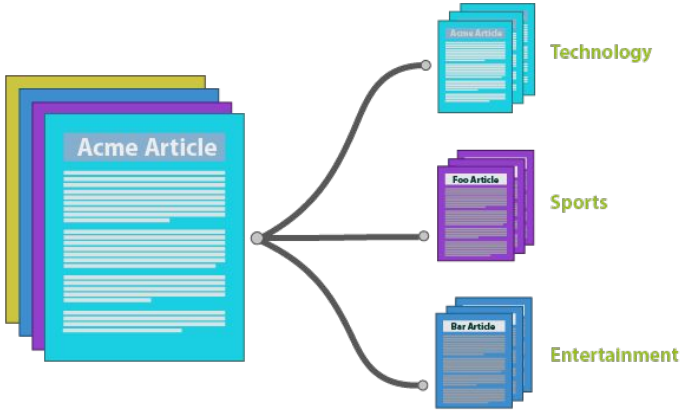
Similitud coseno

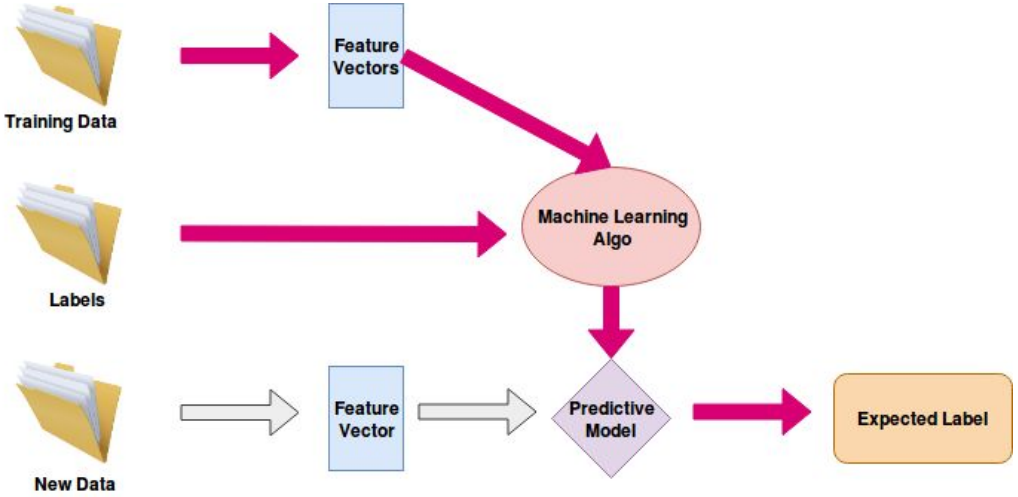
"Se utiliza para evaluar la dirección de dos vectores"

$$\cos(\theta) = \frac{\mathbf{A} \cdot \mathbf{B}}{\|\mathbf{A}\|\|\mathbf{B}\|} = \frac{\sum_{i=1}^{n} A_i B_i}{\sqrt{\sum_{i=1}^{n} A_i^2} \sqrt{\sum_{i=1}^{n} B_i^2}}$$

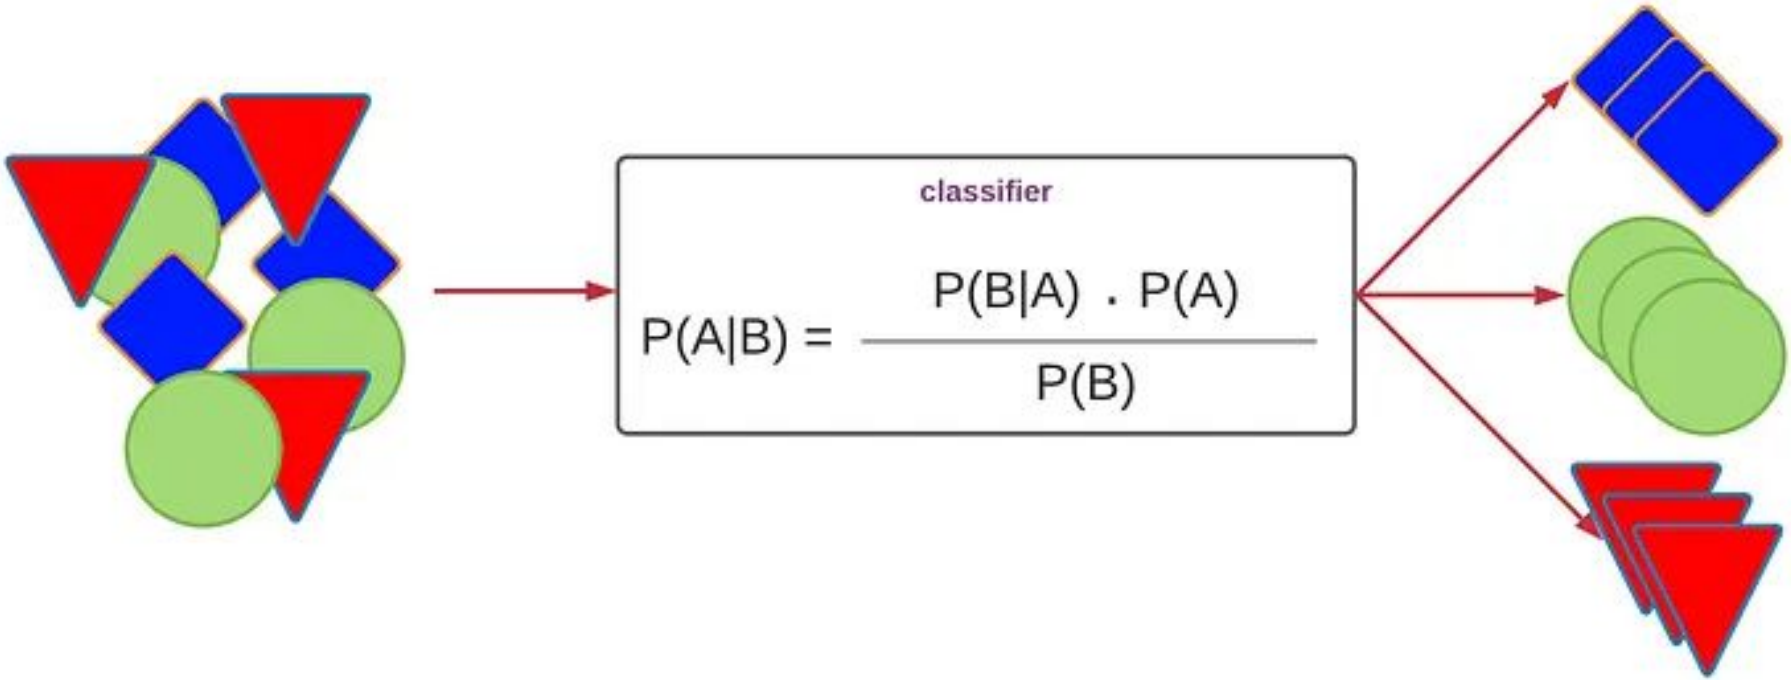
Machine Learning para NLP

Modelo de clasificación de texto





Modelo de clasificación, Naïve Bayes



Modelo de clasificación Naïve Bayes

¿Por qué es "Naive" (Ingenuo)?

Porque asume que cada palabra en una frase es **independiente** de las demás. No le importa el orden; solo le importa si la palabra está ahí.

¿Cómo funciona?

Calcula la probabilidad de que un texto pertenezca a una categoría basándose en las palabras que contiene.

- *Ejemplo:* Si la palabra "Descuento" aparece mucho en correos marcados como "Spam", cuando llegue un correo nuevo con esa palabra, la probabilidad de que sea "Spam" sube.

Fuente StatQuest: https://www.youtube.com/watch?v=O2L2Uv9pdDA

Modelo de clasificación Naïve Bayes



p(Dear | N) = 0.47
p(Friend | N) = 0.29
p(Lunch | N) = 0.18
p(Money | N) = 0.06

p(N) = 0.67

p(N) x p(Dear | N) x p(Friend | N) = 0.09

p(S) x p(Dear | S) x p(Friend | S) = 0.01



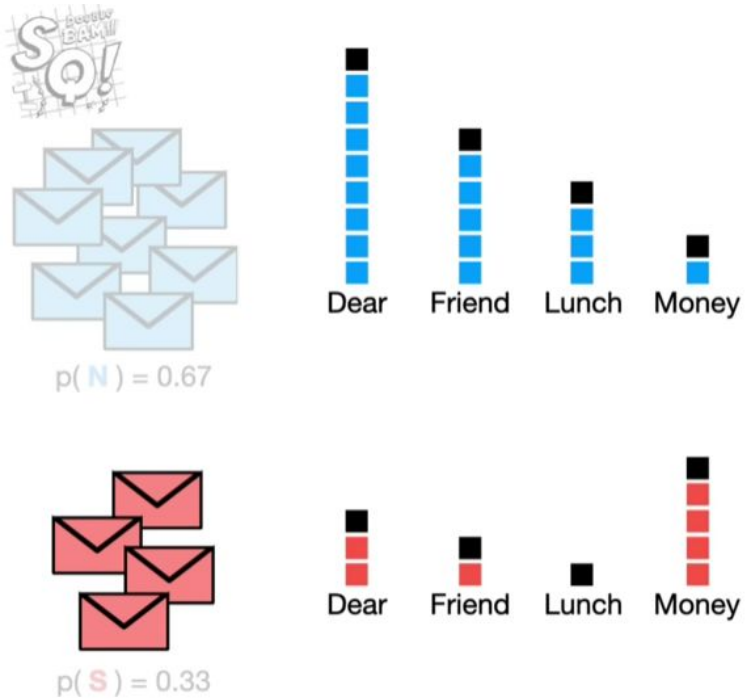
p(Dear | S) = 0.29
p(Friend | S) = 0.14
p(Lunch | S) = 0.00
p(Money | S) = 0.57

p(S) = 0.33

Fuente StatQuest: https://www.youtube.com/watch?v=O2L2Uv9pdDA

Modelo de clasificación Naïve Bayes

Suavizado de Laplace



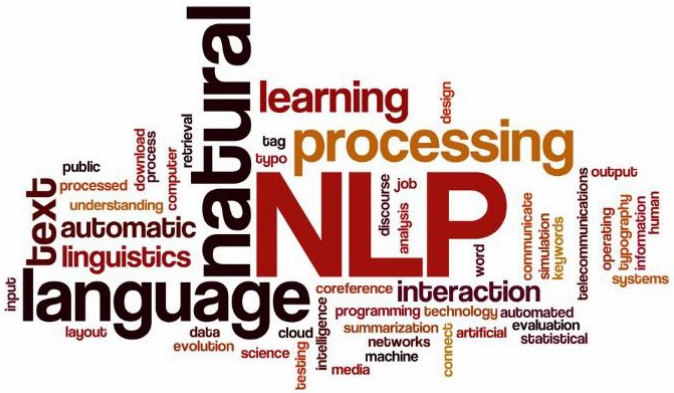
Naive Bayes Multinomial

Variante específica para texto.

Mientras que el Naive Bayes básico solo mira si la palabra *aparece o no*, el **Multinomial** cuenta **cuántas veces** aparece.

Fuente StatQuest: https://www.youtube.com/watch?v=O2L2Uv9pdDA

Representaciones y modelos de tipo “Bolsa de palabras” (BOW)



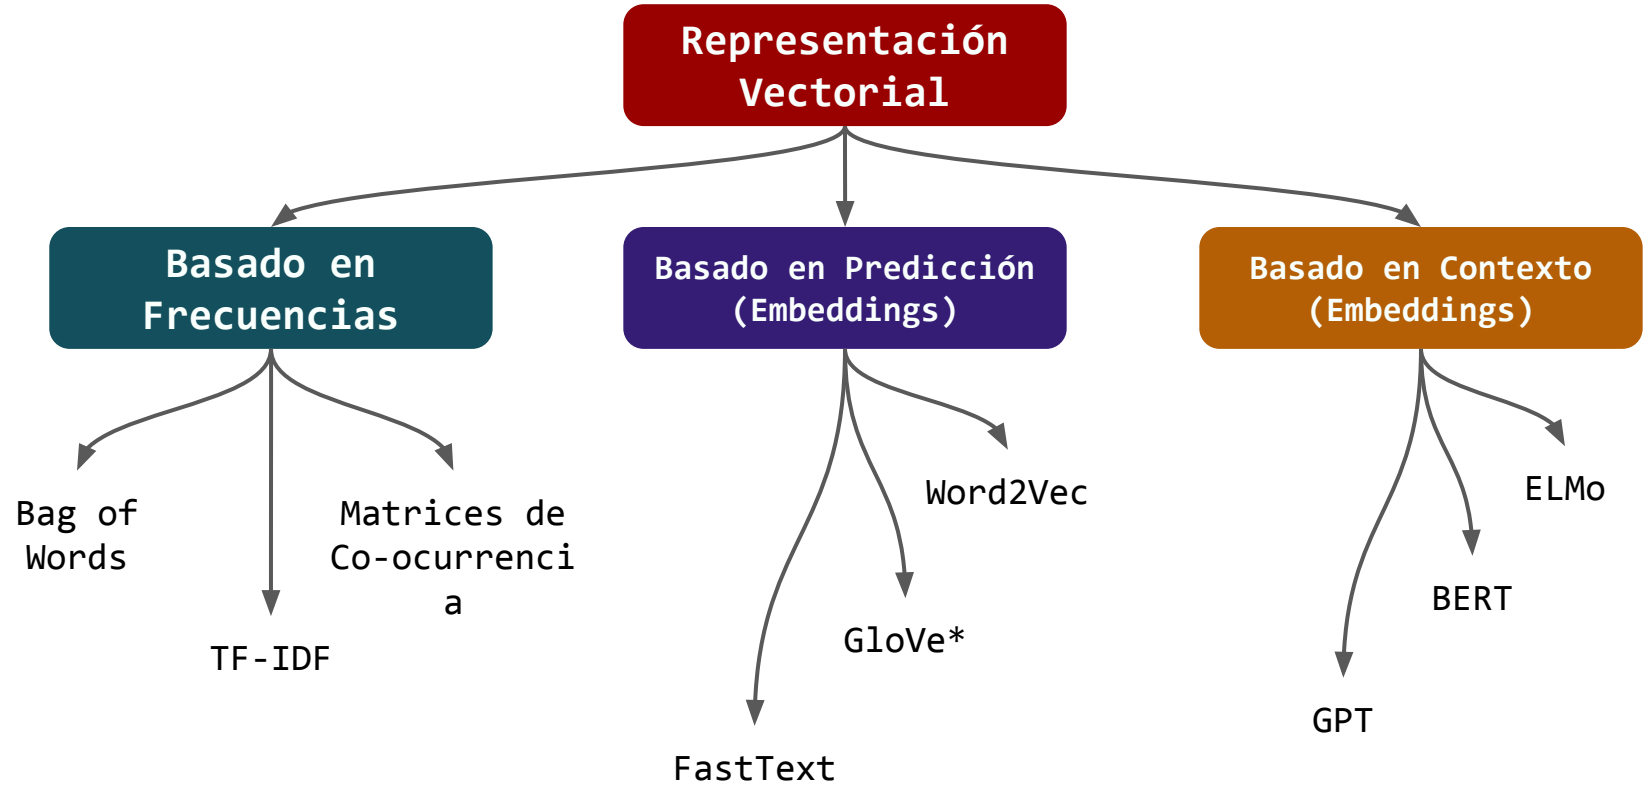
Cualquier modelo o representación (vectorización) de texto en donde el resultado no se modifique con el orden de las palabras es un modelo o representación BOW.

CountVector, OHE, TF-IDF son ejemplos de representaciones BOW
Naïve Bayes es un ejemplo de clasificador tipo BOW

Desafio



NLP Clásico vs NLP + DL vs LLMs



NLP Clásico vs NLP + DL vs LLMs



NLP Clásico

1.- Texto
2.- Tokenización
3.- Stop words removal
4.- Stemming / Lemmatization
5.- Vectorización (BoW, TF-IDF)
6.- Modelo ML

NLP + DL

1.- Texto
2.- Tokenización
3.- Subword tokenization (BPE, WordPiece)
4.- Embeddings
5.- Modelo

LLMs

1.- Texto
2.- Tokenizer (BPE / WordPiece / SentencePiece)
3.- IDs de tokens
4.- Transformer